ANNEXE DU MÉMOIRE DE RECHERCHE APPLIQUÉE

Présenté et soutenu par

Florian PRIVAT

Année universitaire 2025 – 2026

Détecter la désinformation médiatique par la donnée

Vérification automatisée des chiffres de la presse française par recoupement avec les sources officielles

MSc 2 — Manager en Data Marketing

Sous la direction de **LINDA ATTARI & ALEXANDRA YOUSSOFI**

Alternance réalisée au sein de **SMILE**

Tutoré par **FRANCE-ALICE BASQUIN & GAËLLE RENOU**

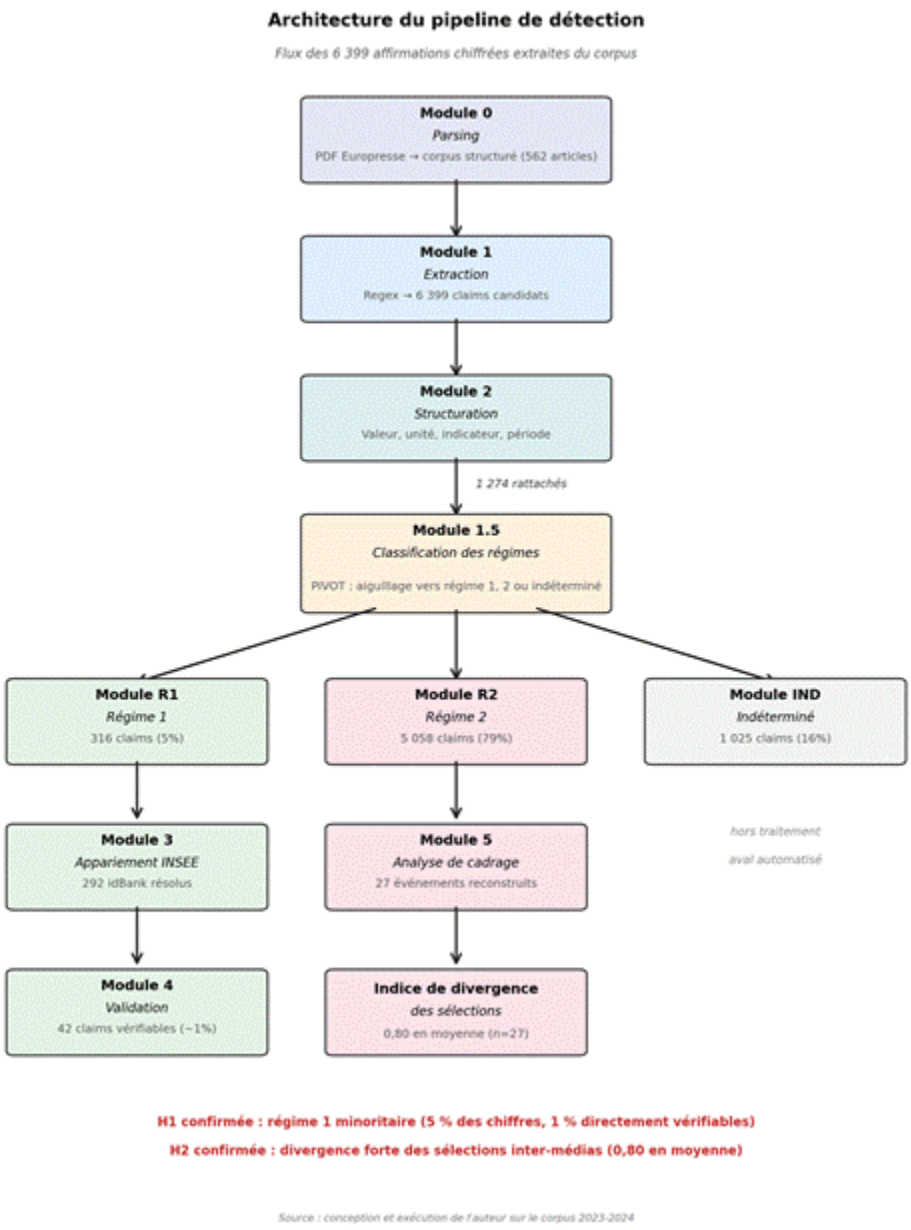
Sommaire

Annexe 1 — Schéma d'architecture du pipeline 3
Annexe 2 — Codebook Entman pour l'analyse de cadrage 4
Annexe 3 — Guide de codage du protocole de validation (section 2.4.2) 7
Annexe 4 — Distribution détaillée du corpus 11

Annexe 1 — Schéma d'architecture du pipeline

Cette annexe complète la section 2.1.2 en représentant visuellement l'enchaînement des six modules du pipeline, le point de bifurcation au module 1.5, et les volumes traités à chaque étape sur le corpus de 562 articles.

Figure A1.



Architecture du pipeline de détection. Le module 1.5 constitue le point de bifurcation entre les affirmations vérifiables (régime 1) et celles relevant du cadrage (régime 2).

Annexe 2 — Codebook Entman pour l'analyse de cadrage

Cette annexe complète la section 2.6 en explicitant les quatre fonctions du cadrage identifiées par Entman (1993) et les marqueurs lexicaux retenus pour leur détection dans le corpus. Le codebook est destiné à une validation par double codage humain.

Rappel du cadre théorique. Selon Entman (1993), cadrer un événement consiste à sélectionner certains aspects de la réalité et à les rendre saillants dans un texte, de manière à promouvoir une définition particulière du problème, une interprétation causale, une évaluation morale ou une recommandation d'action. Ces quatre fonctions ne coexistent pas toujours dans un même énoncé, mais leur repérage systématique permet de comparer les cadrages inter-médias.

F1. Définition du problème (problem definition)

Cette fonction identifie ce qui est présenté comme problématique dans la situation décrite : la nature du phénomène, son ampleur, son caractère anormal ou attendu.

Marqueurs lexicaux retenus :

- Substantifs de mise en cause : « crise », « dérive », « problème », « défi », « menace », « urgence »
- Adjectifs d'ampleur : « massif », « historique », « record », « inédit », « préoccupant »
- Verbes de constat négatif : « alerte », « s'inquiète », « déplore », « dénonce »

Exemple d'usage :

« Le taux de chômage atteint un niveau préoccupant, marquant un record depuis la sortie de crise » → F1 activée (marqueurs : préoccupant, record).

F2. Attribution causale (causal interpretation)

Cette fonction attribue une cause au phénomène décrit : responsabilité d'un acteur, mécanisme économique, facteur exogène.

Marqueurs lexicaux retenus :

- Locutions causales : « en raison de », « du fait de », « à cause de », « en conséquence », « imputable à »
- Verbes d'attribution : « provoque », « entraîne », « génère », « explique », « résulte de »
- Substantifs de responsabilité : « responsabilité », « imputabilité », « faute », « politique »

Exemple d'usage :

« La hausse du déficit s'explique par la baisse des recettes fiscales » → F2 activée (marqueur : s'explique par).

F3. Jugement moral (moral evaluation)

Cette fonction porte une évaluation normative sur la situation ou les acteurs impliqués.

Marqueurs lexicaux retenus :

- Adjectifs évaluatifs : « inacceptable », « irresponsable », « courageux », « lâche », « scandaleux », « légitime »
- Verbes de jugement : « condamner », « saluer », « fustiger », « approuver », « regretter »
- Modalités déontiques : « devrait », « doit », « ne peut pas », « il est urgent de »

Exemple d'usage :

« Le gouvernement doit assumer ses responsabilités face à cette dérive budgétaire » → F3 activée (marqueur : doit assumer, dérive).

F4. Prescription / remède (treatment recommendation)

Cette fonction propose une action ou un ensemble d'actions pour résoudre le problème identifié.

Marqueurs lexicaux retenus :

- Verbes prescriptifs : « proposer », « préconiser », « recommander », « annoncer », « prévoir »
- Substantifs d'action : « plan », « mesure », « réforme », « solution », « politique »
- Locutions injonctives : « il faut », « il convient de », « la solution passe par »

Exemple d'usage :

« Le plan de rigueur annoncé prévoit dix milliards d'économies » → F4 activée (marqueurs : plan, prévoit, dix milliards d'économies).

Limites du codebook

Trois limites doivent être signalées. D'abord, les marqueurs sont indicatifs et non exhaustifs : un même mot peut servir des cadrages opposés selon le contexte, ce qui appelle une validation qualitative. Ensuite, l'inférence lexicale reste aveugle à l'ironie, à la négation et aux constructions elliptiques. Enfin, le codebook ne substitue pas au jugement humain : il constitue un support de codage, dont la fiabilité inter-annotateurs devra être mesurée par un coefficient kappa lors de sa mise en œuvre.

Note : ce codebook doit être ajusté au fil des annotations. Une itération initiale sur un sous-échantillon de 30 à 50 claims permet d'affiner les marqueurs avant le codage complet.

Annexe 3 — Guide de codage du protocole de validation (section 2.4.2)

Cette annexe complète la section 2.4.2 en fournissant le guide de codage destiné aux annotateurs humains chargés de valider la classification automatique des affirmations chiffrées en régimes de vérifiabilité.

Objectif et modalités

L'annotateur doit assigner chaque claim de l'échantillon à l'un des trois régimes suivants, en aveugle par rapport à la décision du classifieur automatique. La modalité retenue est reportée dans la colonne prévue à cet effet du fichier d'annotation.

Modalité	Étiquette	Définition opérationnelle
Régime 1	regime_1	L'affirmation renvoie à une série statistique officielle unique et datée (par ex. taux de chômage BIT au T4 2023 selon l'INSEE). Un verdict de véracité par comparaison à la source est possible.
Régime 2	regime_2	L'affirmation porte sur un chiffre sans référent officiel unique : objectif, prévision, ratio construit, estimation sectorielle, comparaison contextuelle. Aucune série officielle ne lui correspond terme à terme.
Indéterminé	indetermine	L'affirmation ne présente pas de marqueur discriminant permettant de trancher entre régime 1 et régime 2, ou les marqueurs présents se contredisent.

Critères de décision

Trois critères hiérarchisés guident le codage.

Critère 1 : indicateur officiel identifié

La phrase mentionne-t-elle explicitement un indicateur statistique de référence (taux de chômage, indice des prix, croissance du PIB, dette publique, déficit) rattaché à une source officielle française (INSEE, Banque de France, Eurostat) ?

- Oui, et le chiffre est présenté comme une mesure constatée → régime 1
- Oui, mais le chiffre est présenté comme un objectif, une prévision ou une projection → régime 2 (règle de priorité : une projection n'est pas un fait mesuré)
- Non → passer au critère 2

Critère 2 : caractère prospectif de l'énoncé

L'affirmation porte-t-elle sur une valeur future, une prévision, un objectif politique, une estimation ex ante ?

- Oui → régime 2
- Non → passer au critère 3

Critère 3 : attribution à une source institutionnelle

L'affirmation est-elle attribuée à un acteur (gouvernement, ministère, parti politique, entreprise, ONG) plutôt qu'à une institution statistique ?

- Oui → régime 2 (chiffre potentiellement disputé, cadrage)
- Non, aucune attribution claire ni indicateur officiel → régime indéterminé

Exemples annotés

Les exemples ci-dessous illustrent le processus de décision. Ils sont à utiliser lors de la formation des annotateurs.

Affirmation	Régime	Justification
Le taux de chômage s'établit à 7,3 % au quatrième trimestre 2023 selon l'INSEE.	regime_1	Indicateur officiel identifié (chômage BIT), source officielle (INSEE), période précise, verbe de constat.
Le gouvernement vise un déficit ramené à 4,4 % du PIB en 2027.	regime_2	Marqueur de projection (« vise »), année future, chiffre prospectif.
Selon les projections de Bercy, la dette publique atteindra 3 200 milliards d'euros fin 2025.	regime_2	Marqueur prospectif (« projections », « atteindra »), attribution politique.
Le PIB français a progressé de 0,9 % en 2023.	regime_1	Indicateur officiel, valeur constatée, année passée.
Un rapport chiffre à environ 15 milliards d'euros le coût pour les finances publiques.	indetermine	Absence de source officielle explicite, formulation vague (« un rapport »), pas de marqueur prospectif clair.
L'inflation en Espagne s'établit à 2,4 % en juin 2024.	regime_2	Indicateur officiel mais pays étranger sans source française : hors périmètre INSEE.
L'objectif est de créer 300 000 emplois d'ici 2027.	regime_2	Marqueur d'intention (« objectif »), horizon futur.
Les prix à la consommation ont augmenté de 4,9 % en moyenne annuelle en 2023 (INSEE).	regime_1	Indicateur officiel, source explicite, valeur constatée.
Le déficit public a représenté 5,5 % du PIB en 2023.	indetermine	Chiffre officiel mais ratio « en pourcentage du PIB » potentiellement confondu avec taux de croissance (exclusion explicite du classifieur).

Cas ambigus et arbitrage

Certains cas résistent à une décision immédiate. Trois heuristiques d'arbitrage sont recommandées :

- Si la même affirmation pourrait relever du régime 1 sous une condition (par exemple : la présence d'une date précise) qui n'est pas satisfaite dans le texte, choisir indéterminé plutôt que régime 2.
- Si le chiffre est présenté comme provenant d'une institution officielle mais avec une périodisation vague (par exemple : « selon l'INSEE, l'inflation reflue »), choisir indéterminé.
- Les cas restant ambigus après ces heuristiques doivent être discutés entre codeurs pour arriver à un accord, ou tranchés par un tiers codeur qualifié.

Note méthodologique : ce guide doit être stabilisé sur un pré-échantillon de 10 à 20 claims avant le codage complet, afin d'ajuster les critères et de fixer l'usage des heuristiques.

Annexe 4 — Distribution détaillée du corpus

Cette annexe complète la section 2.2 en présentant la distribution des 562 articles selon plusieurs axes : média, année, densité chiffrée. Elle fournit également les volumes intermédiaires (avant déduplication) et les scories résiduelles.

Distribution par média

Média	Articles	Part (%)
Le Monde	102	18,1
Les Échos	96	17,1
Le Figaro	91	16,2
Libération	83	14,8
L'Obs	69	12,3
Le Point	63	11,2
Agence France-Presse	58	10,3
Total	562	100,0

La densité chiffrée moyenne s'établit à 11,4 affirmations par article sur l'ensemble du corpus, avec une variation par titre : Le Figaro se distingue par la densité la plus élevée (13,2 chiffres par article), suivi de près par Le Monde (12,2), tandis que Les Échos présente la densité la plus faible parmi les titres pour lesquels le calcul a été effectué (9,3). Cet écart reflète des formats éditoriaux distincts plutôt qu'un écart de rigueur.

Distribution par année

Année	Articles	Part (%)
2023	294	52,3
2024	268	47,7
Total	562	100,0

Volumes intermédiaires

Le corpus a subi plusieurs étapes de nettoyage entre la collecte initiale et le corpus final utilisé pour l'analyse.

Étape	Volume	Commentaire
Articles bruts issus des 50 exports PDF	755	Volume initial avant contrôle.
Articles avec compteur de mots exploitable	741	98,1 % du volume initial.
Extractions conformes au checksum	729	98,4 % des articles contrôlés.
Anomalies de sur-extraction corrigées	13	Décompte allant jusqu'à 718 % de la valeur attendue dans le cas le plus extrême.
Anomalies de métadonnée « média »	11	Corrigées par normalisation.
Doublons identifiés et retirés	193	Repérés par identifiant Europresse natif.
Corpus final distinct	562	Recoupe un corpus de référence constitué indépendamment.

Scories résiduelles

Cinq articles subsistent dans le corpus final malgré leur caractère atypique : les « agendas » macroéconomiques de l'AFP, denses en chiffres de calendrier (dates, horaires de publication de statistiques à venir) mais dépourvus d'affirmations analytiques. Ils sont neutres pour l'extraction de claims car les patrons n'y détectent pas de motifs statistiques exploitables, mais pourraient être écartés en amont dans une version ultérieure du pipeline.