MÉMOIRE DE RECHERCHE APPLIQUÉE

Présenté et soutenu par

Florian PRIVAT

Année universitaire 2025 – 2026

Détecter la désinformation médiatique par la donnée

Vérification automatisée des chiffres de la presse française par recoupement avec les sources officielles

MSc 2 — Manager en Data Marketing

Sous la direction de **LINDA ATTARI & ALEXANDRA YOUSSOFI**

Alternance réalisée au sein de **SMILE**

Tutoré par **FRANCE-ALICE BASQUIN & GAËLLE RENOU**

SOMMAIRE

Introduction générale **5**
Partie I: Revue de la littérature **8**
1.1 Désordre informatif et données quantitatives 8
1.1.1 Taxonomie du désordre informatif 8
1.1.2 Le rôle des chiffres dans le discours politique et médiatique 9
1.1.3 Les limites du fact-checking manuel 10
1.2 Extraction automatique d'information quantitative 12
1.2.1 Les caractéristiques linguistiques des affirmations quantitatives 12
1.2.2 Les techniques d'extraction fondées sur des règles 13
1.2.3 La reconnaissance d'entités nommées pour le français 14
1.2.4 L'extraction des affirmations quantitatives 15
1.2.5 La normalisation et l'analyse des expressions temporelles 16
1.3 Bases de données officielles et intégration 17
1.3.1 L'écosystème des données publiques françaises 17
1.3.2 Open data et transparence 18
1.3.3 Les bases de connaissances pour le fact-checking 19
1.3.4 L'appariement d'entités et la mise en correspondance sémantique 20
1.3.5 La qualité et la fiabilité des données 21
1.4 Validation et vérification opérationnelle 22
1.4.1 La comparaison numérique et les seuils de tolérance 22
1.4.2 Les systèmes de fact-checking automatisés 23
1.4.3 Les pratiques des fact-checkers professionnels 24
1.4.4 Le contexte français 25
1.5 Le journalisme computationnel 25
Partie II: Méthodologie et résultats. Un pipeline de détection à l'épreuve du corpus **28**
2.1 Cadre méthodologique et architecture du pipeline 29
2.1.1 Problématique opérationnelle et hypothèse des deux régimes 29
2.1.2 Architecture générale du pipeline 30
2.2 Constitution du corpus 32
2.2.1 Collecte et périmètre du corpus 32
2.2.2 Parsing, nettoyage et déduplication 33
2.3 Extraction et structuration des affirmations chiffrées 34
2.3.1 Extraction des affirmations chiffrées 34
2.3.2 Structuration sémantique et temporelle 35
2.4 Classification en régimes de vérifiabilité 37
2.4.1 Règles de classification et résultats 37

2.4.2 Protocole de validation du classifieur 38
2.5 Confrontation aux données officielles (INSEE) 39
2.6 Analyse de cadrage inter-médias 41
2.7 Synthèse des résultats et limites 42
Partie III: Discussion et préconisations 44
3.1 Discussion des résultats 44
3.1.1 Retour sur les hypothèses 44
3.1.2 L'asymétrie de la vérifiabilité: discussion théorique 45
3.2 Préconisations 46
3.2.1 Préconisations pour les rédactions 46
3.2.2 Préconisations pour les fact-checkers et les plateformes 47
3.3 Perspectives et limites de la recherche 49
Conclusion générale 51
Bibliographie 54
Glossaire 63
Note relative à l'usage de l'intelligence artificielle 69
Résumé 70
Abstract 71

Lettre de Remerciement

Au terme de ce travail, je tiens à exprimer ma gratitude à celles et ceux qui en ont rendu la réalisation possible.

Je remercie en premier lieu LINDA ATTARI et ALEXANDRA YOUSSOFI, qui ont encadré cette recherche, pour leurs conseils, leur disponibilité et leur rigueur dans l'accompagnement de chaque étape de ce mémoire.

Mes remerciements vont également à SMILE MARSEILLE et à l'ensemble de l'équipe qui m'a accueilli durant mon alternance, en particulier à FRANCE-ALICE BASQUIN & GAËLLE RENOU, pour la confiance accordée et pour un environnement de travail propice à la conduite de ce projet.

J'adresse enfin ma reconnaissance à INSEEC MSC MARSEILLE et à son corps enseignant pour la formation reçue, ainsi qu'à mes proches, dont le soutien constant a été précieux tout au long de ce parcours.

Introduction générale

Rarement le chiffre aura occupé une place aussi centrale dans le débat public français qu'au cours des années 2023 et 2024. Le reflux de l'inflation après le choc énergétique, les inflexions du taux de chômage, l'ampleur du déficit et l'alourdissement de la dette publique ont nourri une controverse permanente, où chaque acteur avançait ses pourcentages, ses milliards d'euros et ses points de croissance comme autant d'arguments réputés décisifs. Le nombre y jouait un rôle singulier: présenté comme neutre, objectif et difficilement contestable, il semblait pouvoir clore des débats que le seul discours qualitatif laissait ouverts. C'est dans ce constat que s'enracine le présent travail, et dans le paradoxe qui l'accompagne: le chiffre rassure dans la mesure même où il se prête à la manipulation. Sa forme dépersonnalisée lui confère une autorité rhétorique que n'atteint aucun argument qualitatif (Porter, 1995) ; mais cette autorité fait précisément la gravité d'une donnée fausse, tronquée ou sélectionnée, car elle emprunte le prestige de l'objectivité pour porter autre chose qu'un fait établi.

Cette tension dépasse le cadre d'un débat académique. Elle s'inscrit dans un phénomène plus large que Wardle et Derakhshan (2017) proposent de désigner sous le terme de désordre informatif, et qui recouvre la production et la circulation, dans l'espace public, d'informations fausses ou trompeuses. Ce désordre s'accompagne d'une érosion documentée de la confiance envers les médias. Le baromètre Kantar–La Croix de 2019 situait la crédibilité de la presse écrite à 44 %, en recul d'environ huit points sur un an. Dans un tel climat de défiance, la capacité à distinguer un chiffre fiable d'un chiffre trompeur ne relève plus du seul confort intellectuel: elle conditionne la possibilité d'un socle factuel partagé, sans lequel le débat démocratique se prive de sa matière commune. Vérifier les chiffres de la presse revient ainsi à interroger l'un des points les plus sensibles du contrat de confiance qui lie les médias à leur public.

La démarche suppose au préalable de fixer le vocabulaire. On distinguera, à la suite de Wardle et Derakhshan (2017), trois formes de désordre informatif. La mésinformation désigne une information fausse diffusée sans intention de nuire, qu'il s'agisse d'une erreur, d'une approximation ou d'une méprise. La désinformation renvoie à une information fausse propagée délibérément dans le but de tromper. La malinformation, enfin, repose sur des éléments exacts mais mobilisés pour induire en erreur, par exemple un chiffre juste mais sorti de son contexte ou sélectionné de façon orientée. Le fact-checking, ou vérification factuelle, désigne quant à lui l'activité, journalistique à l'origine, consistant à confronter une affirmation à des sources afin

d'en établir la véracité. On appellera enfin donnée chiffrée vérifiable une affirmation numérique susceptible d'être confrontée à une mesure de référence faisant autorité, c'est-à-dire renvoyant à une grandeur définie, datée et produite par une institution statistique. Cette dernière notion est au cœur du mémoire, car c'est elle qui sépare le chiffre qui peut faire l'objet d'un verdict de véracité de celui qui échappe à toute réfutation factuelle.

De ces définitions naît la question qui structure l'ensemble du travail: dans quelle mesure peut-on détecter de la désinformation médiatique par la donnée ? Cette interrogation générale appelle une reformulation opérationnelle, plus étroite mais susceptible d'une mise à l'épreuve empirique: dans quelle mesure peut-on automatiser la vérification des données chiffrées de la presse française par recoupement avec des sources officielles, au premier rang desquelles l'INSEE ? L'objectif n'est pas de construire un détecteur universel de désinformation, mais d'évaluer avec précision la portée réelle d'une telle automatisation, c'est-à-dire de mesurer quelle fraction du discours chiffré s'y prête effectivement, et pourquoi l'autre fraction lui échappe. Le mémoire se propose donc moins de vérifier des chiffres que de déterminer ce que la donnée permet, et ne permet pas, de vérifier dans le discours de presse.

Un tel projet impose de circonscrire son terrain. L'étude porte sur la presse écrite française (quotidiens de référence, presse économique, hebdomadaires et dépêches d'agence) et se limite au champ macroéconomique: chômage, inflation, croissance, dette et déficit publics, sur la période 2023-2024, particulièrement dense en actualité statistique. Ce périmètre restreint procède d'un choix assumé: il fournit un corpus contrôlable et un domaine où les chiffres, adossés à des séries officielles bien établies, se prêtent a priori le mieux à la vérification. En sont en revanche exclus l'audiovisuel et les réseaux sociaux, dont les travaux fondateurs ont documenté qu'ils constituent des vecteurs majeurs de circulation de la désinformation contemporaine (Vosoughi, Roy & Aral, 2018 ; Bronner, 2022), ainsi que les autres champs thématiques (santé, sécurité, environnement) dont les référents statistiques sont plus fragmentés. Ces exclusions bornent la généralisation des conclusions, mais elles sont le prix d'une comparaison rigoureuse sur un matériau homogène.

Pour répondre à cette question, le mémoire mobilise un dispositif empirique conçu selon un double impératif d'interprétabilité et de reproductibilité. Il prend la forme d'un pipeline modulaire, dont chaque étape isole une opération explicable et réexécutable, à rebours des

approches par apprentissage opaque. Ce dispositif est appliqué à un corpus constitué à partir de la base de presse Europresse, puis confronté aux séries de la Banque de données macroéconomiques de l'INSEE. Il s'organise autour d'un cadre analytique central, l'hypothèse des deux régimes de vérifiabilité. Le régime 1, dit de vérifiabilité forte, rassemble les chiffres renvoyant à une série officielle unique et datée, qui peuvent faire l'objet d'un verdict de véracité. Le régime 2, dit de vérifiabilité faible, regroupe les chiffres dépourvus de référent officiel (objectifs, prévisions, ratios, estimations), qui ne peuvent être analysés que sous l'angle du cadrage. De ce cadre découlent deux hypothèses de travail, mises à l'épreuve du corpus: la part des chiffres relevant du régime 1 serait minoritaire (H1), et la sélection des chiffres de régime 2 divergerait fortement d'un média à l'autre pour un même événement (H2).

Le mémoire se déploie en trois temps. La première partie établit l'état de l'art de la détection automatisée de la désinformation chiffrée: elle définit son objet, examine les techniques d'extraction des affirmations quantitatives, recense les sources de données publiques mobilisables et situe les limites documentées du fact-checking, manuel comme automatique. La deuxième partie expose la conception, la mise en œuvre et les résultats du pipeline appliqué au corpus, en suivant sa chaîne de traitement, de la collecte des articles jusqu'à l'analyse de cadrage. La troisième partie discute ces résultats au regard de la littérature, en tire des préconisations pour les producteurs et les vérificateurs de l'information, et trace les perspectives de recherche. C'est par la revue de littérature qu'il convient de commencer, afin de préciser ce que recouvre exactement la notion de désordre informatif et pourquoi les données chiffrées en constituent une cible privilégiée.

Partie I: Revue de la littérature

1.1 Désordre informatif et données quantitatives

1.1.1 Taxonomie du désordre informatif

Penser la détection automatisée de la désinformation suppose d'abord de définir précisément l'objet que l'on cherche à détecter. Pourtant, le terme de « fake news », désormais incontournable dans le débat public, manque de rigueur théorique pour être tout à fait pertinent: trop large, devenu une arme rhétorique et clivante, il recouvre des situations de nature diverse en occultant leurs logiques propres. Pour dépasser cette imprécision, Wardle et Derakhshan (2017) proposent, dans un rapport du Conseil de l'Europe, le cadre conceptuel du désordre informatif (information disorder), qui structure l'analyse autour de deux dimensions: le caractère vrai ou faux de l'information, d'une part, et l'intention de nuire de celui qui la diffuse, d'autre part.

De ces deux axes se déduisent trois catégories distinctes. La mésinformation (misinformation) désigne une information fausse diffusée sans intention de nuire: il s'agit d'erreurs involontaires, d'approximations ou de méprises. La désinformation (disinformation) renvoie à une information fausse diffusée délibérément dans le but de tromper ou de nuire. La malinformation, enfin, repose sur des éléments vrais, mais mobilisés pour porter préjudice, par exemple la divulgation de données réelles sorties de leur contexte, ou la sélection orientée de faits exacts mais trompeurs (Wardle & Derakhshan, 2017).

Cette distinction n'est pas seulement théorique: elle délimite le périmètre de ce qu'un système de vérification fondé sur la donnée peut effectivement traiter. Mettre en regard un chiffre journalistique et une source officielle permet d'en déterminer l'exactitude, et donc d'identifier la mésinformation et la désinformation chiffrées. En revanche, la malinformation, c'est-à-dire un chiffre exact mais décontextualisé ou un cherry-picking statistique, échappe largement à une vérification purement factuelle, puisque la donnée elle-même est correcte. Cette limite, posée dès la taxonomie, conditionne la portée des hypothèses développées dans la suite du mémoire.

La pertinence de ce cadre s'apprécie également au regard des insuffisances du vocabulaire concurrent. En effet, au terme d'une revue systématique de la littérature, Tandoc, Lim et Ling (2018) montrent que l'expression « fake news » englobe des réalités aussi divergentes que la

satire, la parodie, la fabrication de contenu, la manipulation, la publicité déguisée ou la propagande. Cette pluralité d'acceptions confirme la nécessité d'un outil théorique plus rigoureux, tel que le désordre informatif, pour garantir la reproductibilité d'une méthode de détection.

Saisir la circulation de ces contenus requiert, en dernier lieu, d'analyser leurs logiques cognitives et environnementales. Sur le plan individuel, Pennycook et Rand (2021) mettent en évidence que propager de fausses nouvelles relève plutôt d'une forme de paresse cognitive que d'une volonté délibérée de favoriser son camp politique: les individus partagent du faux faute de s'arrêter pour en évaluer la plausibilité, plus que par adhésion idéologique. Sur le plan collectif, l'ampleur du phénomène a été documentée notamment lors de l'élection présidentielle américaine de 2016, où la circulation massive de fausses informations sur les réseaux sociaux a été mise en évidence par Allcott et Gentzkow (2017).

Ces dynamiques s'inscrivent dans un espace public fragmenté. Les travaux de Sunstein (2001) sur les chambres d'écho et de Pariser (2011) sur les bulles de filtres décrivent comment la personnalisation algorithmique et l'entre-soi communautaire favorisent la circulation d'informations homogènes et peu contredites, créant un terrain propice au désordre informatif. Ce cadre taxonomique étant posé, il convient à présent d'examiner une de ses déclinaisons spécifiques, centrale pour ce mémoire: la place des données chiffrées dans le discours médiatique et politique (1.1.2).

1.1.2 Le rôle des chiffres dans le discours politique et médiatique

Si le désordre informatif touche l'ensemble des contenus médiatiques, il prend une dimension particulière lorsqu'il porte sur des données chiffrées. Le chiffre bénéficie en effet d'une autorité sociale spécifique. Porter (1995) montre, dans son histoire de la quantification, comment les nombres se sont imposés comme une « technologie de la confiance »: en apparence neutres, dépersonnalisés et objectifs, ils permettent de trancher des débats là où la confiance interpersonnelle fait défaut, notamment dans la décision publique. Cette objectivité perçue confère au chiffre une force de conviction supérieure à celle d'un argument qualitatif. C'est précisément ce qui rend une donnée erronée si problématique: elle emprunte l'autorité de l'objectivité tout en véhiculant le faux.

Or cette autorité est éminemment exploitable. Huff (1954), dans How to Lie with Statistics, recense les procédés par lesquels la présentation d'un chiffre (choix de l'échantillon, manipulation des échelles, graphiques tronqués) induit le lecteur en erreur sans recourir au mensonge explicite. Best (2001) prolonge cette analyse en s'intéressant à l'usage rhétorique des statistiques dans le débat public: il décrit comment des chiffres approximatifs, voire fabriqués, acquièrent une existence autonome à force d'être repris, cités et amplifiés par les médias, les responsables politiques et les groupes d'intérêt.

La difficulté ne se réduit toutefois pas aux chiffres faux. Blastland et Dilnot (2007) insistent sur le fait qu'un nombre exact peut tout autant tromper, dès lors qu'il est mal contextualisé: absence de point de comparaison, confusion entre grandeurs, effets d'échelle ou de cadrage. Cette observation rejoint directement la catégorie de la malinformation identifiée plus haut (1.1.1) et confirme qu'une part de la tromperie chiffrée relève de l'interprétation et du contexte, et non de la seule véracité de la donnée.

Dans le contexte français, Bronner (2013) analyse les mécanismes par lesquels l'information frappante ou alarmante, souvent étayée par des chiffres, circule plus aisément sur le « marché cognitif » que l'information nuancée. Il met en évidence une forme de crédulité collective face aux quantifications, d'autant plus efficace que le chiffre désamorce l'esprit critique en se présentant comme un fait incontestable.

Il ressort de ces travaux une tension structurante pour ce mémoire: le chiffre est à la fois l'un des registres les plus autoritaires du discours public et l'un des plus aisément manipulables. Cette double caractéristique fait des affirmations quantitatives une cible privilégiée du désordre informatif, et donc une priorité pour toute démarche de vérification. Elle justifie le choix, central dans ce travail, de concentrer la détection sur les données chiffrées de la presse française. Reste à mesurer dans quelle mesure le dispositif actuel de vérification, le fact-checking manuel, est en capacité de répondre à ce défi, ce qu'examine la section suivante (1.1.3).

1.1.3 Les limites du fact-checking manuel

Face à la circulation de données chiffrées trompeuses, la réponse historique du champ journalistique a été le développement du fact-checking. Ce mouvement a connu une croissance institutionnelle marquée: Graves et Cherubini (2016) documentent l'essor des structures de

vérification en Europe, tandis que le recensement de Stencel et Griffin (2020) constate que le nombre d'organisations de fact-checking actives dans le monde a environ triplé en six ans. La vérification factuelle s'est ainsi imposée comme une composante reconnue de l'écosystème médiatique.

Cette montée en puissance se heurte toutefois à une limite structurelle: le fact-checking manuel est une activité intrinsèquement coûteuse en temps et en expertise. Graves (2018) souligne que la vérification suppose une compréhension du contexte, l'exercice d'un jugement et la synthèse de sources multiples, autant d'opérations difficilement automatisables. Les praticiens interrogés dans cette étude rapportent qu'un fact-check classique demande typiquement de l'ordre d'une journée de travail, ce qui borne mécaniquement le volume d'affirmations qu'une rédaction peut traiter. Amazeen (2020) confirme que les organisations de vérification opèrent sous de fortes contraintes de ressources.

Il en résulte un écart persistant entre le volume d'informations potentiellement vérifiables et la capacité réelle de traitement. Même en forte croissance, les structures de fact-checking ne peuvent examiner qu'une fraction des affirmations en circulation, et ce d'autant moins que celles-ci se diffusent en temps réel sur des canaux multiples. Comme le relèvent Stencel et Griffin (2020), la progression du nombre d'acteurs n'a pas comblé ce déficit de couverture, qui demeure une faiblesse centrale du dispositif manuel.

C'est précisément cet écart de passage à l'échelle qui motive le recours à l'automatisation. Graves (2018) insiste néanmoins sur le fait que la vérification entièrement automatisée reste hors de portée pour la plupart des contenus: à ce jour, elle ne donne de résultats fiables que sur un univers étroit d'affirmations essentiellement statistiques, pour lesquelles des données de référence faisant autorité sont disponibles, et toujours sous supervision humaine. Ce constat est doublement structurant pour ce mémoire. D'une part, il justifie l'intérêt d'un système d'assistance à la vérification. D'autre part, il en délimite le périmètre réaliste: les affirmations chiffrées adossées à des sources officielles constituent précisément le terrain où l'automatisation est aujourd'hui crédible. Encore faut-il, en amont, être capable d'extraire automatiquement ces affirmations du texte, ce qu'examine la section suivante (1.2).

1.2 Extraction automatique d'information quantitative

1.2.1 Les caractéristiques linguistiques des affirmations quantitatives

La section précédente a établi que l'automatisation n'est crédible que sur un sous-ensemble d'affirmations. Encore faut-il pouvoir isoler ces affirmations dans le flux du texte. Cette opération suppose au préalable de caractériser ce qui distingue, sur le plan linguistique, une affirmation factuelle vérifiable d'une opinion ou d'un énoncé sans portée informative. Vlachos et Riedel (2014) ont posé les bases de cette tâche en proposant une définition formelle du fact-checking computationnel et en construisant un premier jeu de données structuré: vérifier un énoncé suppose d'abord de l'identifier comme une affirmation factuelle, c'est-à-dire un énoncé présenté comme vrai et confrontable à une source.

Toutes les affirmations factuelles ne se valent cependant pas du point de vue de la vérification. Hassan, Li et Tremayne (2015) introduisent la notion d'affirmation « vérifiable et digne d'intérêt » (check-worthy), qu'ils apprennent à détecter automatiquement à partir de débats présidentiels américains. Leur travail montre que ces affirmations présentent des régularités linguistiques exploitables: certaines structures syntaxiques, certains marqueurs lexicaux et la présence d'entités précises permettent de les distinguer des énoncés purement subjectifs. Parmi ces marqueurs, les éléments quantitatifs (nombres, pourcentages, montants, unités de mesure, expressions temporelles) occupent une place de premier plan, car ils signalent un énoncé objectivement confrontable à une donnée de référence.

L'existence de régularités stables est confirmée par la constitution de corpus annotés de grande taille. Arslan, Hassan, Li et Tremayne (2020) ont publié un jeu de données de référence de 23 533 phrases, annotées par 101 codeurs sur une période de 26 mois et réparties en trois catégories: énoncés non factuels, énoncés factuels sans importance, et énoncés factuels dignes de vérification. La taille de ce corpus et le recours à de nombreux annotateurs attestent qu'il est possible de définir la notion d'affirmation vérifiable de manière suffisamment consistante pour entraîner et évaluer des systèmes automatiques.

Les affirmations quantitatives ont par ailleurs fini par être traitées comme une catégorie à part entière, ce qui marque l'actualité de la recherche et rejoint directement l'objet de ce mémoire. La tâche 3 du CheckThat ! Lab de CLEF 2025 a ainsi porté spécifiquement sur la vérification

d'affirmations numériques et temporelles, en s'appuyant sur le jeu de données QuanTemp, qui rassemble plus de 15 000 affirmations de ce type assorties d'un corpus d'évidences associé. Cette tâche, reconduite dans l'édition CLEF 2026, confirme que la vérification des données chiffrées constitue désormais un problème de recherche autonome, distinct de la vérification factuelle générale en raison des spécificités d'interprétation qu'imposent les quantités, les dates et les comparaisons.

Ces régularités linguistiques fondent la faisabilité de l'extraction, mais n'en garantissent pas à elles seules la mise en œuvre. Identifier qu'une phrase contient une affirmation quantitative est une chose ; en extraire de façon fiable la valeur, l'unité et la période concernées en est une autre. La section suivante examine les techniques mobilisables à cette fin, à commencer par les approches fondées sur des règles (1.2.2).

1.2.2 Les techniques d'extraction fondées sur des règles

L'extraction automatique d'information dans des textes non structurés n'est pas un problème nouveau. Elle s'est formalisée dès les années 1990 autour des conférences Message Understanding Conference, dont Grishman et Sundheim (1996) retracent l'histoire et qui ont notamment introduit la tâche de reconnaissance d'entités nommées. À cette époque, les systèmes reposaient massivement sur des règles écrites manuellement (patrons lexico-syntaxiques, expressions régulières, grammaires locales) destinées à repérer dans le texte des structures récurrentes. Cette approche par règles constitue le socle historique de l'extraction d'information.

Si la recherche académique s'est par la suite tournée massivement vers l'apprentissage automatique, les approches par règles demeurent largement dominantes dans les déploiements industriels. Chiticariu, Li et Reiss (2013) documentent ce décalage entre une littérature centrée sur le machine learning et une pratique où les systèmes à base de règles restent privilégiés, en raison de leur transparence, de la facilité d'y intégrer une connaissance métier, et de leur maintenabilité, autant de propriétés que les modèles statistiques, plus opaques et dépendants de données d'entraînement annotées, n'offrent pas aussi directement. Cet argument est central pour le présent travail, dont le positionnement relève de l'ingénierie de la donnée plutôt que de l'apprentissage: l'interprétabilité du dispositif, indispensable à un usage journalistique, plaide en faveur de méthodes dont chaque décision reste explicable.

Les affirmations quantitatives se prêtent particulièrement bien à ce type d'approche, car leur forme de surface est hautement régulière. Un pourcentage, un montant ou une quantité se présentent selon des motifs stables que des expressions régulières capturent efficacement, par exemple un nombre suivi d'un symbole d'unité. Friedl (2006) constitue à cet égard la référence sur la conception de telles expressions. Au-delà des expressions régulières brutes, des bibliothèques de traitement du langage comme spaCy (Honnibal & Montani, 2017 ; Explosion AI, 2020) industrialisent cette logique en proposant des composants de mise en correspondance de motifs (matchers) opérant non seulement sur les chaînes de caractères mais aussi sur des attributs linguistiques, et en mettant à disposition des modèles pré-entraînés pour le français.

Cette approche présente des avantages décisifs pour le cas étudié: absence de besoin en données d'entraînement, contrôle fin du comportement du système et traçabilité des extractions. Elle a pour contrepartie une certaine fragilité face à la variabilité linguistique (formulations inattendues, incertitude lexicale, tournures elliptiques) qui impose un travail de maintenance et d'enrichissement continu des règles. Les motifs réguliers ne suffisent toutefois pas à eux seuls: la reconnaissance d'entités plus complexes requiert des modèles dédiés, dont les performances pour le français sont examinées dans la section suivante (1.2.3).

1.2.3 La reconnaissance d'entités nommées pour le français

Les approches par règles décrites précédemment trouvent leur prolongement naturel dans la reconnaissance d'entités nommées (Named Entity Recognition, NER), qui vise à repérer dans le texte des catégories d'entités telles que les dates, les montants, les pourcentages ou les quantités. Pour le français, l'outillage est aujourd'hui mature. La tradition du traitement automatique des langues francophone est ancienne, comme en témoigne le pipeline SxPipe (Sagot & Boullier, 2008), et elle a été profondément renouvelée par les modèles de langue pré-entraînés.

Le modèle de référence en la matière est CamemBERT (Martin et al., 2020), qui a établi l'état de l'art pour plusieurs tâches du français, dont la reconnaissance d'entités nommées, avec des performances de l'ordre de 89 % de F1 sur le French Treebank. Cette maturité signifie qu'un système appliqué peut s'appuyer sur de tels modèles à titre de composant prêt à l'emploi, sans avoir à les développer ni à les ré-entraîner.

Ce point appelle toutefois une précision de périmètre. Le présent mémoire ne relève pas de l'apprentissage automatique: son objet est l'ingénierie d'un dispositif de vérification, non l'amélioration de modèles de NER. La reconnaissance d'entités y est donc mobilisée, le cas échéant, comme une brique auxiliaire venant compléter l'extraction par règles, et non comme une contribution en soi. Les performances évoquées ci-dessus ne constituent pas un résultat de ce travail mais un simple indicateur de la disponibilité de l'outillage. L'enjeu spécifique reste l'extraction fiable des affirmations chiffrées elles-mêmes, que la section suivante aborde de manière ciblée (1.2.4).

1.2.4 L'extraction des affirmations quantitatives

Parmi les affirmations vérifiables, celles qui contiennent des chiffres constituent un sous-ensemble particulièrement saillant, et c'est précisément ce que confirme la recherche empirique. En construisant ClaimBuster, Hassan, Adair et leurs collègues (2015) ont observé que la présence d'un nombre cardinal est le meilleur prédicteur de la nature « vérifiable et digne d'intérêt » d'un énoncé: dans leur corpus, 45 % des phrases jugées dignes de vérification contiennent une valeur numérique, contre seulement 6 % des phrases non factuelles. Ce résultat fournit une justification empirique directe au choix, central dans ce mémoire, de cibler les données chiffrées: se concentrer sur les chiffres ne revient pas à restreindre arbitrairement le champ, mais à viser le matériau le plus susceptible de mériter une vérification.

La détection d'affirmations centrées sur des nombres a par ailleurs donné lieu à des travaux spécialisés. Dans le domaine financier, Chen, Huang et Chen (2020) ont introduit NumClaim, une tâche de détection fine d'affirmations centrée sur les données numériques des textes d'investisseurs. Ces travaux s'inscrivent dans une lignée plus large autour de la notion d'attachement de numéral (numeral attachment), qui consiste à relier un nombre à l'entité qu'il qualifie. Si le domaine d'application diffère du nôtre, le principe consistant à placer le nombre au centre de l'analyse est directement transposable.

Des systèmes plus récents abordent enfin la vérification d'affirmations chiffrées de manière intégrée. Fu et al. (2024) présentent ainsi le prototype Aletheia, conçu pour la vérification automatisée d'affirmations fondées sur des données. Le système mobilise un modèle de langue pré-entraîné pour analyser la sémantique de l'affirmation et guider la recherche d'évidences, puis

restitue le résultat sous forme de tables de données et de visualisations. Au-delà de la seule vérification, ce travail met en avant la dimension de communication du verdict, un aspect en résonance directe avec l'exigence d'interprétabilité indispensable à un usage journalistique.

Identifier et isoler une affirmation chiffrée ne suffit toutefois pas à la rendre comparable à une donnée de référence. Encore faut-il en normaliser les composantes: convertir « 7,3 % » en une valeur exploitable, rattacher un montant à son unité, et surtout résoudre les expressions temporelles qui en délimitent la portée. Ces opérations de normalisation, et en particulier l'analyse temporelle, font l'objet de la section suivante (1.2.5).

1.2.5 La normalisation et l'analyse des expressions temporelles

Une affirmation chiffrée extraite d'un texte n'est pas encore comparable à une donnée officielle: elle doit d'abord être normalisée, c'est-à-dire ramenée à une forme canonique exploitable par une machine. Cette opération concerne la valeur et son unité, mais elle est particulièrement délicate pour les expressions temporelles, qui délimitent la portée d'un chiffre. Un énoncé tel que « le chômage a reculé l'an dernier » suppose de résoudre une référence relative en une période absolue ; or la correspondance entre la période visée par l'affirmation et celle de la donnée de référence est l'un des points les plus critiques de la vérification. L'étiquetage temporel (temporal tagging) constitue à cet égard un sous-domaine mature du traitement du langage.

Plusieurs outils à base de règles répondent à ce besoin et s'accordent avec l'orientation interprétable du présent travail. HeidelTime (Strötgen & Gertz, 2013) est un étiqueteur temporel multilingue et inter-domaines, qui couvre de nombreuses langues dont le français et résout les expressions temporelles en valeurs normalisées. SUTime (Chang & Manning, 2012), développé à Stanford, repose lui aussi sur un ensemble de règles pour reconnaître et normaliser les mentions de temps. La nature explicite de ces systèmes en facilite l'audit et le contrôle, propriété précieuse pour un dispositif destiné à un usage journalistique.

Une approche alternative consiste à apprendre l'interprétation des expressions temporelles plutôt qu'à l'encoder par des règles. Angeli, Manning et Jurafsky (2012), avec le système Parsing Time, proposent ainsi une interprétation probabiliste fondée sur une grammaire compositionnelle, capable de gérer des formulations que des règles figées captureraient mal. Cette voie n'est pas retenue ici, conformément au choix méthodologique en faveur de méthodes

transparentes, mais elle illustre le spectre des solutions disponibles et leurs compromis respectifs entre robustesse et explicabilité.

Ces traitements reposent enfin sur une étape amont souvent sous-estimée: la tokenisation, c'est-à-dire le découpage du texte en unités élémentaires. Loin d'être triviale, elle achoppe précisément sur les éléments qui nous intéressent (nombres, abréviations, dates composées) comme l'illustre l'outil de tokenisation flexible LT TTT (Grover et al., 2000). Une segmentation défaillante compromet en cascade l'extraction et la normalisation.

Au terme de cette section, la chaîne d'extraction peut être considérée comme établie sur le plan conceptuel: il est possible d'identifier les affirmations chiffrées, de les isoler et d'en normaliser les composantes en un triplet exploitable associant une valeur, une unité et une période. Reste la question décisive de la référence: pour statuer sur la véracité d'un chiffre, encore faut-il disposer de données officielles structurées et fiables auxquelles le confronter. C'est l'objet de la partie suivante (1.3).

1.3 Bases de données officielles et intégration

1.3.1 L'écosystème des données publiques françaises

La vérification automatisée d'un chiffre suppose de disposer d'une référence faisant autorité, structurée et accessible par programme. Sur ce plan, la France dispose d'un écosystème de données publiques particulièrement développé. La plateforme data.gouv.fr, opérée par Etalab, centralise les données ouvertes de l'administration. Elle recensait plus de 73 000 jeux de données en mai 2026 et continue de croître à un rythme soutenu. Cette abondance établit la disponibilité d'une matière première considérable, même si la pertinence de chaque jeu pour la vérification reste variable.

Pour les données économiques et sociales chiffrées qui intéressent ce mémoire, la source centrale est toutefois l'INSEE. Sa banque de données macroéconomiques (BDM) est exposée depuis 2015 sous la forme d'un service web ouvert et gratuit, fondé sur le standard international SDMX et accessible via une API de type REST. Elle donne accès à plus de 150 000 séries chronologiques, chacune identifiée par un code unique (idBank) permettant d'interroger directement une valeur pour une période donnée. C'est précisément le type de référence

(autoritative, structurée et requêtable automatiquement) qu'exige un dispositif de vérification: la donnée officielle peut être récupérée de manière déterministe et confrontée à l'affirmation extraite.

À l'échelle européenne, Eurostat publie des données harmonisées en s'appuyant sur ce même standard SDMX, ce qui garantit l'interopérabilité entre les sources et autorise des recoupements. Cette convergence technique entre l'INSEE et Eurostat est un atout: elle permet de mobiliser, pour une même grandeur, des définitions harmonisées, par exemple le taux de chômage au sens du Bureau international du travail, distinct des chiffres d'inscription administrative.

L'existence de ces sources officielles structurées et accessibles par API constitue la condition technique qui rend le projet de ce mémoire réalisable, et distingue le cas français de contextes où la donnée publique demeure fermée ou peu exploitable. La disponibilité ne vaut cependant pas suffisance: mobiliser ces sources soulève des enjeux de gouvernance de l'ouverture des données, ainsi que des questions de qualité et de fiabilité, qui sont abordés dans les sections suivantes (1.3.2 puis 1.3.5).

1.3.2 Open data et transparence

La richesse de l'écosystème français décrit précédemment s'inscrit dans un mouvement plus large d'ouverture des données publiques et de gouvernement ouvert. Janssen, Charalabidis et Zuiderwijk (2012) en analysent les bénéfices attendus (transparence, responsabilité démocratique, réutilisation économique, participation citoyenne), mais ils identifient aussi des barrières à l'adoption et un ensemble de « mythes » entourant l'ouverture des données. Le principal d'entre eux est l'idée selon laquelle la simple publication d'un jeu de données engendrerait automatiquement de la valeur: en réalité, celle-ci ne se matérialise que lorsque la donnée est effectivement réutilisable.

Cette nuance s'applique directement à ce mémoire. Rendre des statistiques officielles disponibles est une condition nécessaire à leur exploitation, mais elle n'est pas suffisante. La réutilisation se heurte à des obstacles concrets: formats hétérogènes, documentation incomplète, difficulté à repérer le bon jeu de données, qualité variable des métadonnées. Ce sont précisément les barrières qu'un dispositif de vérification automatique rencontre lorsqu'il essaie d'apparier une

affirmation à la donnée de référence pertinente. La simple disponibilité d'un jeu ne garantit donc ni son accessibilité réelle ni son utilité.

Zuiderwijk et Janssen (2014) prolongent cette analyse en proposant un cadre de comparaison des politiques d'ouverture des données, de leur mise en œuvre et de leur impact. Ils montrent que les politiques diffèrent sensiblement d'un contexte à l'autre et que l'impact n'est jamais acquis: il dépend de choix d'implémentation tels que l'adoption de standards, les licences retenues et la qualité de l'infrastructure d'accès. Sous cet angle, les choix techniques de l'écosystème français (standard SDMX, accès par API, évoqués en 1.3.1) constituent une implémentation favorable, qui réduit les barrières de réutilisation identifiées dans la littérature.

L'écosystème français apparaît ainsi propice non seulement par son volume, mais aussi par des modalités d'ouverture qui en facilitent l'exploitation par programme. Au-delà des données publiques généralistes, la recherche en vérification factuelle a toutefois constitué ses propres bases de connaissances, conçues spécifiquement pour l'entraînement et l'évaluation des systèmes. La section suivante examine ces ressources dédiées (1.3.3).

1.3.3 Les bases de connaissances pour le fact-checking

Au-delà des données publiques généralistes, la recherche en vérification factuelle s'est dotée de ressources spécifiques, qui se répartissent en deux familles: des jeux de données annotés servant à entraîner et évaluer les systèmes, et des bases de connaissances structurées servant de source de vérification. Le jeu de référence de la première famille est FEVER (Thorne et al., 2018), qui rassemble 185 445 affirmations dérivées de Wikipédia. Chacune est étiquetée comme appuyée, réfutée ou insuffisamment documentée, et accompagnée des phrases qui servent de preuve. FEVER s'est imposé comme le banc d'essai de la vérification d'affirmations face à un texte non structuré.

Or les affirmations économiques et sociales sont quantitatives et résident le plus souvent dans des tableaux plutôt que dans du texte courant. C'est précisément ce que vise TabFact (Chen et al., 2020), conçu pour la vérification face à une preuve structurée: le jeu comprend 117 854 énoncés annotés portant sur 16 573 tables issues de Wikipédia, classés comme confirmés ou réfutés. Ce déplacement vers la vérification fondée sur des tables est directement pertinent pour

ce mémoire, dont les données de référence (les séries de l'INSEE) sont elles aussi de nature tabulaire et appellent un raisonnement sur des structures et non sur du seul texte.

À côté de ces bancs d'essai, les bases de connaissances structurées fournissent des faits de référence directement interrogeables. DBpedia (Auer et al., 2007) en constitue l'exemple fondateur: le projet extrait de Wikipédia une connaissance structurée et interrogeable, et transforme ainsi un contenu encyclopédique en faits exploitables par une machine. De telles bases peuvent servir de source de vérification, mais leur couverture des statistiques économiques françaises fines et actualisées demeure limitée au regard d'une source spécialisée comme l'INSEE.

Ces ressources attestent à la fois la maturité du domaine et une lacune persistante. FEVER et TabFact sont essentiellement anglophones et adossés à Wikipédia, tandis que DBpedia est généraliste. Aucune n'est rattachée à la statistique publique française, ce qui conforte le positionnement de ce travail. L'exploitation de toute base structurée suppose par ailleurs de relier les entités mentionnées dans l'affirmation à l'enregistrement adéquat de la base. C'est le problème de l'appariement d'entités, qu'examine la section suivante (1.3.4).

1.3.4 L'appariement d'entités et la mise en correspondance sémantique

Relier une affirmation extraite à la série de référence pertinente relève de l'appariement d'entités (entity linking), qui consiste à associer une mention textuelle à son référent dans une base de connaissances. Shen, Wang et Han (2015) en proposent une synthèse de référence, articulée autour de deux difficultés. D'abord la variation des dénominations: une même entité peut être désignée de plusieurs façons. Ensuite l'ambiguïté: une même mention peut renvoyer à plusieurs référents possibles. Résoudre ces deux problèmes est la condition pour qu'une affirmation soit confrontée à la bonne donnée, et non à une donnée voisine.

Les travaux fondateurs du domaine se sont appuyés sur Wikipédia. Cucerzan (2007) a ouvert la voie de la désambiguïsation d'entités nommées à grande échelle en exploitant les données de Wikipédia, en particulier les informations de contexte et de catégorie, pour choisir le bon référent. Rao, McNamee et Dredze (2013) ont ensuite systématisé la tâche consistant à relier des entités extraites à l'enregistrement adéquat d'une base, en formalisant un enchaînement en deux temps: génération de candidats, puis désambiguïsation.

Appliqué à ce mémoire, le problème prend une forme particulière. Les « entités » à apparier ne sont pas des noms propres, mais des concepts statistiques (« le chômage des jeunes », « le taux d'inflation ») qui doivent être mis en correspondance avec la série INSEE exacte, identifiée par son idBank, à la bonne granularité géographique et temporelle et selon la bonne définition (le chômage au sens du Bureau international du travail n'étant pas l'inscription administrative). La difficulté ne porte donc plus sur la désambiguïsation de noms propres, comme dans l'appariement sur Wikipédia, mais sur la mise en correspondance d'un concept économique et de ses qualificatifs avec un identifiant de série unique. C'est un appariement contraint, mais loin d'être trivial.

L'appariement d'entités constitue ainsi le point d'articulation entre l'extraction et la vérification. Sa fiabilité conditionne toute la chaîne: une correspondance erronée invalide le verdict, quelle que soit la qualité du reste du dispositif. Un appariement correct ne garantit pour autant pas que la donnée de référence soit elle-même exempte de difficultés: les chiffres officiels sont révisés, parfois provisoires, et reposent sur des définitions variables. C'est la question de la qualité et de la fiabilité des données, qu'aborde la section suivante (1.3.5).

1.3.5 La qualité et la fiabilité des données

Disposer de la bonne série et l'apparier correctement ne suffit pas encore: la donnée de référence est elle-même porteuse d'une qualité variable, dont dépend la validité du verdict. La qualité des données constitue à cet égard un champ structuré. Batini et Scannapieco (2016) la formalisent à travers plusieurs dimensions: exactitude, complétude, cohérence, fraîcheur temporelle. Ces dimensions sont directement opératoires pour la vérification, car confronter un chiffre de presse à une série officielle suppose que cette dernière soit exacte, complète et à jour pour la période considérée.

Lorsque la réponse provient de plusieurs sources, le problème se complexifie. Naumann (2002) propose un cadre de réponse aux requêtes piloté par la qualité dans les systèmes d'information intégrés: des critères de qualité de l'information y guident la sélection des sources et leur intégration. Ce point est pertinent dès lors qu'une vérification mobilise plusieurs origines, par exemple un recoupement entre l'INSEE et Eurostat: choisir la source faisant autorité et la plus à jour relève alors d'une décision de qualité, et non d'un simple accès.

Les statistiques officielles présentent en outre des complications spécifiques que ce cadre permet de nommer. La révision statistique d'abord: les chiffres publiés sont fréquemment mis à jour de manière rétroactive, passant d'une valeur provisoire à une valeur révisée ; un même indicateur peut donc légitimement prendre des valeurs différentes selon le moment de consultation, si bien qu'un chiffre de presse jugé « faux » au regard de la série actuelle pouvait être exact à la date de sa publication. S'y ajoutent la variabilité des définitions (par exemple le chômage au sens du BIT contre l'inscription administrative) et les effets d'arrondi (« 7 % » pour « 7,24 % »), qui rendent inopérante toute comparaison fondée sur une stricte égalité. La confrontation doit au contraire intégrer des seuils de tolérance et un alignement temporel explicite.

Au terme de cette partie, la question de la référence peut être considérée comme cernée. Des sources officielles structurées existent et sont accessibles par API (1.3.1), portées par une dynamique d'ouverture des données dont les limites sont documentées (1.3.2), complétées par des bases de connaissances issues de la recherche (1.3.3), atteignables au prix d'un appariement d'entités fiable (1.3.4), mais exploitables seulement sous des précautions explicites de qualité (1.3.5). Reste à examiner comment opérer concrètement la confrontation: comment comparer les valeurs, fixer les seuils de tolérance, et quels systèmes réalisent déjà cette validation. C'est l'objet de la partie suivante (1.4).

1.4 Validation et vérification opérationnelle

1.4.1 La comparaison numérique et les seuils de tolérance

Une fois la valeur d'une affirmation extraite et la série de référence récupérée, la vérification se ramène en apparence à comparer deux nombres. Vlachos et Riedel (2015) ont montré que cette tâche est bien définie et traitable: ils identifient et vérifient des affirmations simples portant sur des propriétés statistiques (par exemple la population ou le taux d'inflation d'un pays) en générant des énoncés à partir de caractéristiques d'une base de connaissances, puis en les confrontant aux valeurs de référence. Leur travail établit que la vérification numérique de propriétés statistiques est faisable par une approche structurée à base de règles, directement analogue à la confrontation d'un chiffre de presse avec une série de l'INSEE.

Cette comparaison n'est toutefois pas un test d'égalité stricte, pour les raisons établies en 1.3.5. Les révisions statistiques, la variabilité des définitions et les arrondis font qu'une correspondance

exacte n'est ni attendue ni requise. La vérification doit donc reposer sur des seuils de tolérance, c'est-à-dire un écart maximal acceptable entre la valeur affirmée et la valeur officielle. Cet écart, par exemple un dixième de point pour un taux de chômage, est calibré selon l'indicateur et selon le niveau d'arrondi observé dans le texte source. La fixation de ces seuils est une décision méthodologique aux conséquences directes sur les faux positifs et les faux négatifs.

Il en découle un verdict gradué plutôt que binaire. Un chiffre peut être exact, plausible (c'est-à-dire compris dans la tolérance), imprécis, faux ou invérifiable. Une échelle graduée rend mieux compte de la réalité des données statistiques qu'une dichotomie vrai/faux et rejoint la nuance des évaluations produites par les fact-checkers professionnels. Ce choix d'une gradation conditionne la conception ultérieure du dispositif.

La logique de comparaison et les seuils constituent ainsi le cœur opérationnel de la vérification ; encore faut-il les inscrire dans des systèmes complets. La section suivante examine les systèmes de fact-checking automatisés qui mettent en œuvre de telles chaînes de bout en bout (1.4.2).

1.4.2 Les systèmes de fact-checking automatisés

Plusieurs systèmes intègrent les étapes décrites précédemment (identification, extraction, vérification) au sein de chaînes opérationnelles. ClaimBuster (Hassan, Zhang, Arslan et al., 2017) est présenté comme le premier système de fact-checking automatisé de bout en bout: il surveille les discours en direct, les réseaux sociaux et l'actualité, attribue à chaque phrase un score de « vérifiabilité digne d'intérêt », et la met en correspondance avec un référentiel de vérifications existantes. Sur la tâche de détection des affirmations dignes de vérification, le système atteint une précision de 79 % et un rappel de 74 % (Hassan et al., 2017).

Le domaine s'est depuis structuré et a fait l'objet de synthèses. Guo, Schlichtkrull et Vlachos (2022) proposent un panorama complet du fact-checking automatisé. Ils organisent la tâche en trois temps (détection des affirmations, recherche de preuves, prédiction du verdict) et cartographient les jeux de données et les méthodes existants. Cette synthèse situe le présent travail dans un paysage de recherche désormais bien balisé.

Une préoccupation récurrente est l'explicabilité. Kotonya et Toni (2020) consacrent une revue au fact-checking automatisé explicable, en soutenant qu'un verdict dépourvu de justification est de portée limitée, particulièrement en contexte journalistique, où le raisonnement et les preuves

importent autant que la conclusion. Cet impératif renforce l'exigence d'interprétabilité qui a guidé les choix méthodologiques de ce mémoire, de l'extraction par règles à la traçabilité de l'appariement.

Ces systèmes demeurent toutefois majoritairement anglophones et adossés à Wikipédia ou à des référentiels de vérifications ; aucun n'est arrimé à la statistique publique française. Au-delà des systèmes, comprendre ce que vérifier veut dire suppose enfin d'observer la manière dont les fact-checkers professionnels travaillent réellement (1.4.3).

1.4.3 Les pratiques des fact-checkers professionnels

Automatiser la vérification suppose de comprendre la pratique humaine que l'on cherche à assister. Graves (2016), dans son étude de référence sur l'essor du fact-checking politique dans le journalisme américain, montre qu'il s'agit d'une pratique d'interprétation et de délibération. Le fact-checker sélectionne les affirmations à vérifier, réunit des preuves, exerce un jugement et produit un verdict argumenté ; il n'effectue pas une simple consultation mécanique. La vérification est un travail de raisonnement, ce qui en circonscrit d'emblée la part automatisable.

Cette pratique repose sur des méthodes codifiées. Le Verification Handbook coordonné par Silverman (2016) compile les techniques professionnelles de vérification de l'information et des sources, formalisant un savoir-faire. C'est précisément cette codification méthodologique qui rend une automatisation partielle envisageable: là où les étapes sont explicites et régies par des règles, elles peuvent être assistées par un logiciel.

Le rapport des professionnels à l'automatisation reste néanmoins ambivalent. Brandtzaeg, Følstad et Chaparro Domínguez (2018) documentent les perceptions des fact-checkers et font apparaître des réserves vis-à-vis d'outils susceptibles de diluer le jugement éditorial ou la transparence. Ce constat tempère tout techno-optimisme: un système automatisé a davantage de chances d'être adopté comme un assistant préservant le contrôle du journaliste que comme un substitut, ce qui rejoint la conclusion de Graves (2018) sur la nécessité de maintenir « l'humain dans la boucle ».

Ces pratiques et ces outils sont surtout documentés dans le monde anglophone ; le contexte français possède ses propres acteurs et dynamiques, qu'examine la dernière section de cette partie (1.4.4).

1.4.4 Le contexte français

En France, le fact-checking professionnel s'est structuré autour de cellules de vérification rattachées aux rédactions. AFP Factuel, le service de l'Agence France-Presse, compte parmi les plus actifs de l'espace francophone, aux côtés d'unités installées dans les grands titres de presse. Cet ancrage institutionnel témoigne de la reconnaissance du fact-checking comme fonction journalistique à part entière.

Ce développement répond à une érosion de la confiance dans les médias. Le baromètre Kantar–La Croix de 2019 situe la crédibilité de la presse écrite à 44 %, en recul de huit points sur un an. Cette défiance donne à la vérification factuelle un enjeu démocratique: reconstituer une base factuelle commune.

La recherche française éclaire ces dynamiques. Cardon, Cointet et Mazières (2018), dans « La revanche des neurones », analysent le tournant algorithmique qui reconfigure la circulation de l'information ; Badouard, Mabi et Sire (2016) interrogent quant à eux la gouvernance de l'expression en ligne au-delà des seuls « points de contrôle ». Ces travaux inscrivent la désinformation et son traitement dans la transformation plus large de l'espace public numérique en France.

Au terme de cette partie, les composantes du dispositif de vérification sont identifiables. La comparaison opérationnelle est bien définie (1.4.1) et mise en œuvre par des systèmes matures mais essentiellement anglophones (1.4.2). Elle s'appuie sur une pratique professionnelle codifiée, qui repose néanmoins sur le jugement (1.4.3). Elle s'inscrit enfin dans un contexte français marqué par la défiance et par une activité de vérification active, mais qui ne dispose pas de système relié à la statistique publique (1.4.4). Cette convergence dessine la lacune que ce travail entend combler, et conduit à le situer dans le cadre plus large du journalisme computationnel (1.5).

1.5 Le journalisme computationnel

L'ensemble des éléments examinés jusqu'ici (désordre informatif chiffré, extraction, données de référence, validation) s'inscrit dans un cadre commun: celui du journalisme computationnel. Cohen, Hamilton et Turner (2011) en posent l'acte fondateur avec un véritable appel aux armes: ils définissent le journalisme computationnel comme l'application de la puissance de calcul et

des algorithmes à la collecte, à l'évaluation et à la présentation de l'information, et invitent explicitement les chercheurs en bases de données et en informatique à s'engager au service du journalisme de responsabilité. Le projet de ce mémoire s'inscrit pleinement dans ce programme.

Flew et al. (2012) en formulent la promesse: automatiser la collecte et l'analyse des données pour étendre la capacité journalistique, en particulier dans le champ exigeant du journalisme de responsabilité fondé sur les données. C'est précisément cette promesse que poursuit un dispositif de vérification numérique automatisé: étendre la portée de la vérification au-delà de la capacité manuelle, en réponse directe au déficit de passage à l'échelle identifié plus haut (1.1.3).

Encore faut-il situer ce travail avec précision dans un champ dont les contours sont mal stabilisés. Coddington (2015) clarifie le « tournant quantitatif » du journalisme en distinguant trois courants souvent confondus: le journalisme assisté par ordinateur, le journalisme de données et le journalisme computationnel. Il caractérise ce dernier par l'abstraction, l'automatisation et l'application d'une pensée computationnelle. Cette distinction permet de positionner le présent travail sans ambiguïté: il relève du journalisme computationnel, automatisation et traitement algorithmique au service de la vérification, et se distingue du journalisme de données, qui vise avant tout à raconter des histoires à partir de chiffres.

Le cadre contemporain de ce champ est enfin dressé par Diakopoulos (2019) qui, dans « Automating the News », analyse la participation croissante des algorithmes à la production de l'information, depuis la génération automatique de contenus jusqu'à l'examen des responsabilités algorithmiques. Il défend un modèle hybride dans lequel l'automatisation augmente le jugement humain plutôt qu'elle ne le remplace. Cette posture conforte l'orientation « assistant et non substitut » déjà dégagée à propos des pratiques professionnelles (1.4.3).

Au terme de cette revue de littérature, les éléments se rejoignent en un raisonnement d'ensemble. Le désordre informatif touche aussi les chiffres, dont l'autorité rhétorique rend la manipulation particulièrement efficace (1.1) ; ces affirmations chiffrées peuvent être extraites du texte par des techniques outillées et interprétables (1.2) ; il existe, en France, des sources officielles structurées et accessibles par API pour les vérifier (1.3) ; et des méthodes ainsi que des systèmes de validation opérationnelle sont disponibles, au sein d'une pratique professionnelle codifiée (1.4), le tout s'inscrivant dans le programme du journalisme computationnel (1.5).

De cette synthèse émerge une lacune précise. Les systèmes existants sont essentiellement anglophones et adossés à des sources généralistes ou encyclopédiques. Aucun n'articule l'extraction automatisée d'affirmations chiffrées avec l'écosystème français de la statistique publique, qu'il s'agisse de l'INSEE ou d'Eurostat. C'est cet écart que ce travail vise à combler, en concevant un dispositif de vérification des données chiffrées de la presse française par recoupement avec les sources officielles. La partie suivante en expose la méthodologie

Partie II: Méthodologie et résultats. Un pipeline de détection à l'épreuve du corpus

La première partie a dressé l'état de l'art de la détection automatisée de la désinformation chiffrée. Elle est partie de la définition de son objet, le désordre informatif (Wardle & Derakhshan, 2017), pour parcourir ensuite les techniques d'extraction des affirmations quantitatives, les ressources de données publiques disponibles et les limites documentées du fact-checking, manuel comme automatique. Il en ressort un constat structurant: la donnée chiffrée se présente comme le point d'appui factuel du discours, mais tous les chiffres ne se prêtent pas au même type de vérification. Ce constat, resté théorique en partie 1, devient ici l'objet d'une mise à l'épreuve empirique.

La présente partie expose la conception, la mise en œuvre et les résultats d'un pipeline de détection appliqué à un corpus de presse française. La démarche est doublement contrainte. Elle répond d'abord à un impératif d'interprétabilité, chaque décision du système devant pouvoir être justifiée. Elle répond ensuite à un souci de reproductibilité, chaque étape étant isolée, testée et réexécutable. Loin de viser un détecteur universel, le dispositif est construit pour répondre à une question précise et mesurer sa propre portée: dans quelle mesure, et pour quelle fraction du discours chiffré, la confrontation à la donnée officielle permet-elle effectivement de trancher ?

Le fil conducteur en est l'hypothèse des deux régimes de vérifiabilité, formulée en section 2.1. Le régime 1 rassemble les chiffres rattachables à une série statistique officielle unique, qui peuvent faire l'objet d'un jugement de véracité. Le régime 2 rassemble les chiffres sans référent officiel, qui ne peuvent être analysés que sous l'angle du cadrage. De cette distinction découlent deux hypothèses de travail: la part des chiffres relevant du régime 1 est minoritaire (H1), et la sélection des chiffres de régime 2 diverge fortement d'un média à l'autre pour un même événement (H2).

La partie est organisée selon la chaîne de traitement. La section 2.1 pose le cadre méthodologique et l'architecture générale du pipeline. La section 2.2 décrit la constitution du corpus, de la collecte au nettoyage. Les sections 2.3 à 2.6 suivent les étapes du traitement: extraction et structuration des affirmations chiffrées (2.3), classification en régimes de vérifiabilité (2.4), confrontation des chiffres vérifiables aux données de l'INSEE (2.5) et analyse de cadrage des chiffres non vérifiables (2.6). La section 2.7 synthétise les résultats et en discute

les limites. Chaque section suit une trame constante (problème méthodologique, choix de conception justifiés, résultats sur le corpus) et les chiffres rapportés proviennent de l'exécution effective du pipeline.

2.1 Cadre méthodologique et architecture du pipeline

2.1.1 Problématique opérationnelle et hypothèse des deux régimes

La première partie a établi que la détection automatisée de la désinformation chiffrée se heurte à une difficulté préalable: toutes les affirmations numériques ne se prêtent pas au même type de vérification. La taxonomie du désordre informatif (Wardle & Derakhshan, 2017) distingue la mésinformation et la désinformation, qui peuvent faire l'objet d'un contrôle factuel, de la malinformation, où un élément exact est mobilisé de façon trompeuse et échappe largement à une réfutation par la donnée. Transposée au cas des chiffres de presse, cette distinction impose de ne pas traiter de la même manière un taux officiel daté et un objectif politique chiffré: le premier renvoie à une mesure, le second à une intention. La problématique générale du mémoire, qui interroge dans quelle mesure la donnée permet de détecter la désinformation médiatique, doit donc être reformulée en termes opérationnels avant toute mise en œuvre.

Cette reformulation conduit à poser une hypothèse centrale, qui structure l'ensemble du dispositif empirique: la détectabilité d'une affirmation chiffrée par confrontation aux données officielles n'est pas une propriété uniforme du corpus, mais dépend du régime de vérifiabilité auquel l'affirmation appartient. Nous distinguons deux régimes. Le régime 1, dit de vérifiabilité forte, regroupe les chiffres qui renvoient à une série statistique officielle unique et identifiable: un taux de chômage au sens du Bureau international du travail, un glissement annuel de l'indice des prix, une variation trimestrielle du produit intérieur brut. Pour ces chiffres, la question « est-ce vrai ? » est bien posée: un verdict est possible par comparaison à la source de référence (INSEE dans ce cas présent).

Le régime 2, dit de vérifiabilité faible, rassemble au contraire les chiffres dépourvus de référent officiel unique: objectifs budgétaires, prévisions, estimations sectorielles, ratios construits, données disputées ou décontextualisées. Pour ceux-ci, la question de la véracité est mal posée, non parce que le chiffre serait nécessairement faux, mais parce qu'aucune mesure officielle ne lui correspond directement. Ce qui devient alors analysable n'est plus la véracité mais le cadrage

(framing): la manière dont différents médias sélectionnent, contextualisent et mettent en récit les mêmes chiffres (Entman, 1993). Le régime 2 déplace ainsi l'objet d'analyse, de la vérification vers la comparaison inter-médias.

De cette hypothèse centrale découlent deux hypothèses de travail, testées dans les sections suivantes. H1: la part des chiffres relevant du régime 1 est minoritaire au sein du discours de presse économique. L'essentiel des affirmations chiffrées n'est pas rattachable à une série officielle unique, de sorte que le fact-checking automatique, même techniquement abouti, ne couvre qu'une fraction limitée du corpus. H2: au sein du régime 2, la sélection des chiffres diverge fortement d'un média à l'autre pour un même événement. Le cadrage se manifeste de façon mesurable dans le choix même des données citées ou omises, indépendamment de tout jugement sur leur exactitude.

Cette construction en deux régimes constitue le positionnement propre du mémoire. Elle prend acte des limites du fact-checking automatique documentées en partie 1 (couverture partielle, dépendance à des sources structurées, difficulté du raisonnement contextuel selon Graves, 2018), non pour les contourner mais pour en faire un résultat: la frontière entre ce qui est vérifiable et ce qui ne l'est pas devient elle-même un objet de mesure. Les sections 2.2 à 2.6 décrivent le pipeline conçu pour opérationnaliser cette distinction et en quantifier les deux versants ; la section 2.7 en discute les résultats et les limites.

2.1.2 Architecture générale du pipeline

Le dispositif empirique prend la forme d'un pipeline modulaire en six étapes, chacune isolant une opération et produisant une sortie exploitable par la suivante. Cette modularité répond à deux exigences. La reproductibilité d'abord, chaque étape étant indépendamment testable et réexécutable. L'interprétabilité ensuite, condition posée dans la première partie pour qu'un système de vérification soit défendable devant un lecteur ou un jury. À rebours d'une approche par apprentissage de bout en bout, opaque par construction, chaque décision du pipeline (extraction d'un chiffre, attribution d'un indicateur, classement dans un régime) repose sur des règles explicites et justifiables.

Le module 0 (parsing) convertit les exports PDF de la base de presse Europresse en un corpus structuré d'articles, en isolant le texte de chaque article de ses métadonnées éditoriales (média, date, titre).

Le module 1 (extraction) identifie dans chaque texte les affirmations contenant une donnée chiffrée, par un jeu d'expressions régulières adaptées aux conventions typographiques françaises (virgule décimale, séparateur de milliers, unités).

Le module 1.5 (classification des régimes) constitue le pivot conceptuel du dispositif: il assigne chaque affirmation chiffrée au régime 1 ou au régime 2, selon qu'elle renvoie ou non à une série statistique officielle identifiable. Cette classification détermine l'aiguillage du chiffre dans la suite du pipeline.

Le module 2 (structuration) transforme chaque chiffre brut en une structure exploitable: valeur numérique normalisée, unité, indicateur économique de rattachement, période de référence et modificateurs éventuels.

Les affirmations de régime 1 sont dirigées vers le module 3 (appariement INSEE), qui résout l'identifiant de série (idBank) correspondant et interroge l'API de la Banque de données macroéconomiques de l'INSEE, puis vers le module 4 (validation), qui établit un verdict de véracité par écart à la valeur officielle.

Les affirmations de régime 2 sont dirigées vers le module 5 (analyse de cadrage), qui mesure, pour un même événement chiffré, la divergence des sélections opérées par les différents médias.

Cette architecture matérialise directement l'hypothèse des deux régimes: le point de bifurcation du pipeline (module 1.5) est aussi le lieu où se joue la frontière de la vérifiabilité. Les deux branches produisent des résultats de nature complémentaire: un tableau de fact-checking pour le régime 1, une analyse de cadrage pour le régime 2. Ces deux sorties correspondent aux deux hypothèses de travail H1 et H2. La numérotation non entière du module de classification (1.5) reflète son statut: inséré entre l'extraction et la vérification, il n'ajoute pas une opération de traitement mais une décision d'orientation.

Les sections suivantes détaillent chaque étape selon une trame constante: le problème méthodologique posé, les choix de conception et leur justification, puis les résultats obtenus sur le corpus. Les chiffres rapportés proviennent de l'exécution du pipeline sur le corpus constitué

pour ce mémoire ; les valeurs dont la confirmation suppose un accès en ligne aux sources officielles ou une validation manuelle sont explicitement signalées comme telles.

2.2 Constitution du corpus

2.2.1 Collecte et périmètre du corpus

Le corpus a été constitué à partir de la base de presse Europresse, agrégateur donnant accès au texte intégral de la presse francophone. Le choix d'une base professionnelle plutôt que d'une collecte par moissonnage web répond à un impératif de qualité et de traçabilité des sources: chaque article y est accompagné de métadonnées éditoriales normalisées (titre du média, date de publication, rubrique, nombre de mots revendiqué) qui permettent un contrôle ultérieur de l'extraction. Le périmètre thématique couvre les principaux indicateurs macroéconomiques traités dans la presse généraliste et économique française, à savoir le chômage, l'inflation, la croissance, la dette et le déficit publics, sur la période 2023-2024, qui concentre une actualité statistique dense (réforme des retraites, reflux de l'inflation, débats budgétaires).

La sélection des titres vise un équilibre entre sensibilités éditoriales, condition nécessaire à l'analyse de cadrage de la section 2.6. La presse de référence (Le Monde, Le Figaro, Libération), la presse économique (Les Échos), les hebdomadaires (L'Obs, Le Point) et les dépêches d'agence (Agence France-Presse) y sont représentés. La présence des dépêches AFP est méthodologiquement importante: produites en amont du traitement éditorial, elles offrent un point de comparaison entre le matériau brut de l'information chiffrée et sa reprise différenciée par les rédactions.

Concrètement, la collecte a pris la forme de cinquante exports PDF générés depuis Europresse, totalisant après traitement 755 articles bruts. Ce format d'export, conçu pour la lecture humaine et non pour le traitement automatique, impose une étape de conversion délicate, décrite à la section 2.2.2: la mise en page sur deux colonnes, les encarts, les légendes de photographies et les pieds de page de copyright doivent être distingués du corps de l'article. Le périmètre ainsi constitué ne prétend pas à l'exhaustivité, mais à la représentativité raisonnée d'un sous-champ précis, le traitement chiffré de la conjoncture économique, suffisamment homogène pour que la comparaison inter-médias y soit pertinente.

Deux limites de périmètre doivent être posées d'emblée. D'une part, le corpus est circonscrit à la presse écrite: l'audiovisuel et les réseaux sociaux, dont les travaux fondateurs ont documenté qu'ils constituent des vecteurs majeurs de circulation de la désinformation contemporaine (Vosoughi, Roy & Aral, 2018 ; Bronner, 2022), en sont absents. D'autre part, la période 2023-2024 et le champ macroéconomique orientent les résultats vers un type particulier de chiffre, l'indicateur conjoncturel, dont la vérifiabilité est a priori plus élevée que celle d'autres domaines (santé, sécurité, environnement). Ces choix, qui restreignent la portée des conclusions, sont assumés au profit d'un corpus contrôlable et d'une comparaison rigoureuse, et seront rediscutés en section 2.7.

2.2.2 Parsing, nettoyage et déduplication

La conversion des exports PDF Europresse en corpus structuré constitue une étape technique sous-estimée mais déterminante: la qualité de tout le traitement en aval dépend de la fidélité de l'extraction du texte. Le module 0 segmente chaque PDF en articles en s'appuyant sur les seuils typographiques (taille du titre, bornes des colonnes), isole l'encart de métadonnées éditoriales (média, type de source, couverture géographique, date), puis reconstitue le corps de l'article en gérant la mise en page sur deux colonnes et le recollage des césures. La fiabilité de l'extraction est contrôlée par un checksum: le nombre de mots extrait est comparé au nombre de mots revendiqué par Europresse pour chaque article.

Sur les 755 articles issus des cinquante PDF, ce contrôle valide 729 extractions sur les 741 disposant d'un compteur de référence, soit un taux de conformité de 98,4 %. Deux anomalies récurrentes ont néanmoins été identifiées et corrigées. La première est la sur-extraction: sur certaines mises en page de cahiers spéciaux, le segmenteur ne détectait pas la frontière de l'article suivant et agrégeait plusieurs articles en un seul, gonflant le décompte de mots jusqu'à 718 % de la valeur attendue dans le cas le plus extrême. La correction a consisté à tronquer le corps à la première occurrence du pied de page de copyright Europresse, marqueur déterministe de fin d'article ; treize articles ont ainsi été rectifiés. La seconde anomalie touchait onze articles dont la métadonnée « média » avait capté un intitulé de rubrique au lieu du nom du titre ; elle a été corrigée par normalisation.

Une étape de déduplication s'est révélée indispensable. Un même article peut figurer dans plusieurs exports, et certaines dépêches sont reprises à l'identique: 193 doublons ont été identifiés par leur identifiant Europresse natif et retirés, en conservant pour chaque identifiant la version dont le taux d'extraction était le plus proche de l'optimum. Le corpus final compte ainsi 562 articles distincts. Ce total recoupe exactement celui d'un corpus de référence constitué indépendamment, ce qui valide la procédure de déduplication.

Le corpus final se répartit entre Le Monde (102 articles), Les Échos (96), Le Figaro (91), Libération (83), L'Obs (69), Le Point (63) et l'AFP (58), sur la période de janvier 2023 à décembre 2024 (294 articles en 2023, 268 en 2024). Cette répartition assure une représentation suffisante de chaque sensibilité éditoriale pour l'analyse comparative. Une scorie résiduelle mérite d'être signalée: cinq « agendas » macroéconomiques de l'AFP, denses en chiffres de calendrier (dates, horaires) mais dépourvus d'affirmations analytiques, subsistent dans le corpus. Ils sont neutres pour l'extraction de claims (section 2.3) mais pourraient être écartés en amont dans une version ultérieure du pipeline.

2.3 Extraction et structuration des affirmations chiffrées

2.3.1 Extraction des affirmations chiffrées

Une fois le corpus constitué, la première opération de traitement consiste à repérer, dans chaque article, les phrases porteuses d'une donnée chiffrée. La partie 1 a montré que la présence d'un nombre cardinal constitue le meilleur prédicteur du caractère vérifiable d'une affirmation: dans le jeu de données de référence du domaine, 45 % des phrases jugées dignes de vérification contiennent une valeur numérique, contre 6 % des phrases non factuelles (Hassan, Adair et al., 2015). Le chiffre n'est donc pas un détail du discours, mais son point d'appui factuel, ce qui justifie d'en faire l'unité de base de l'extraction.

Le module 1 repose sur une approche par règles plutôt que par apprentissage. Ce choix, en cohérence avec l'impératif d'interprétabilité posé en 2.1.2, se justifie aussi par la nature du matériau: les conventions typographiques du chiffre en français sont stables et bien définies (virgule décimale, espace insécable comme séparateur de milliers, unités récurrentes telles que le pourcentage, le point, le milliard d'euros). Des expressions régulières capturent ces motifs: pourcentages (« 7,3 % », « 0,9 % »), grands nombres et valeurs monétaires (« 2,5 milliards

d'euros », « 150 mds € »), variations en points (« + 0,2 point ») et effectifs avec séparateurs (« 42 000 », « 3 000 000 »). Chaque phrase contenant au moins un de ces motifs est retenue comme claim candidat, accompagné de la valeur brute repérée et de sa position.

Un dispositif d'exclusion écarte les faux positifs typiques: numéros de page, dates traitées comme des nombres, références légales ou pourcentages insérés dans des expressions non statistiques. La granularité retenue est la phrase: un même énoncé peut contenir plusieurs chiffres, mais l'extraction conserve le premier motif pertinent par phrase afin de préserver le lien entre le chiffre et son contexte immédiat, nécessaire à la structuration qui suit (section 2.3.2). Ce choix privilégie la précision du rattachement contexte-chiffre au détriment d'un relevé exhaustif de chaque valeur d'une phrase dense.

Appliqué aux 562 articles du corpus, le module 1 extrait 6 399 affirmations chiffrées, soit une moyenne de 11,4 par article (médiane de 10, maximum de 81). Quatorze articles ne produisent aucun claim. Il s'agit soit d'« agendas » macroéconomiques de l'AFP (denses en chiffres de calendrier mais dépourvus d'affirmations en phrase), soit d'articles d'opinion à faible teneur quantitative. Ces zéros sont légitimes et non des échecs d'extraction. La densité chiffrée varie selon les titres: Le Figaro et Le Monde sont les plus denses (13,2 et 12,2 chiffres par article), Les Échos le moins (9,3), ce qui reflète des formats éditoriaux distincts plutôt qu'un écart de rigueur.

Cette première étape établit le dénominateur de toute l'analyse: 6 399 chiffres forment l'univers des affirmations potentiellement vérifiables. C'est par rapport à ce total que se mesureront la part rattachable à une série officielle et, in fine, la portée réelle du fact-checking automatique.

2.3.2 Structuration sémantique et temporelle

Un chiffre brut extrait de son contexte, par exemple « 7,5 % » ou « 3 milliards », n'est pas exploitable pour une vérification: il faut d'abord le qualifier. Le module 2 transforme chaque claim candidat en une structure normalisée comportant cinq composantes: une valeur numérique convertie (virgule décimale en point, gestion des ordres de grandeur « milliards » et « millions »), une unité (pourcentage, point, milliard d'euros, effectif), un indicateur économique de rattachement, une période de référence et d'éventuels modificateurs d'incertitude (« environ », « près de », « plus de »).

L'identification de l'indicateur s'opère par appariement à un lexique de mots-clés associés à chacun des domaines suivis (chômage, inflation, produit intérieur brut, dette, déficit, salaire, population). Cette opération est décisive: un chiffre sans indicateur rattachable ne pourra jamais être confronté à une série officielle. Sur les 6 399 claims, 1 274 (20 %) sont rattachés à l'un des indicateurs cibles ; les 5 125 autres, bien que numériquement valides, portent sur des objets hors périmètre (chiffres électoraux, prix sectoriels, grandeurs diverses) et sont d'emblée écartés de la branche de fact-checking. Cette proportion constitue un premier indice en faveur de l'hypothèse H1: la majorité des chiffres de presse ne relève pas des indicateurs macroéconomiques de référence.

La résolution temporelle vise à associer chaque chiffre à sa période d'observation, condition d'une comparaison correcte avec la donnée officielle. Le module repère les références explicites, notamment les trimestres (« au quatrième trimestre 2023 », « T4 2023 »), les mois (« en décembre 2023 ») et les années, selon une logique de proximité dans la phrase, inspirée des étiqueteurs temporels à base de règles tels que SUTime (Chang & Manning, 2012). En l'absence de mention explicite, la période retombe sur l'année de publication de l'article. Cette stratégie de repli constitue une limite importante, analysée en 2.5 et 2.7: elle garantit qu'un chiffre reçoit toujours une période, mais ne distingue pas la période extraite du texte de la période héritée par défaut, ce qui fragilise l'appariement temporel qui suivra.

La répartition des unités sur les claims structurés éclaire la nature du discours chiffré: 64 % sont exprimés en pourcentage, le reste se partageant entre milliards d'euros, effectifs et points. Par ailleurs, 575 claims portent sur une variation (« en hausse de 0,2 point ») plutôt que sur un niveau, distinction que le module enregistre car elle conditionne la confrontation: comparer une variation à un niveau officiel produirait un verdict erroné.

À l'issue du module 2, chaque affirmation chiffrée est donc dotée d'une description complète de son sens. Cette structuration est la condition de possibilité de la classification en régimes (section 2.4): c'est en mobilisant l'indicateur, l'unité et les marqueurs de la phrase que le module suivant pourra décider si un chiffre renvoie à une mesure officielle vérifiable ou relève du cadrage.

2.4 Classification en régimes de vérifiabilité

Le module 1.5 constitue le pivot du dispositif: il décide, pour chaque affirmation chiffrée, si elle renvoie à une série statistique officielle vérifiable (régime 1), si elle relève du cadrage (régime 2), ou si elle ne peut être classée avec certitude dans l'une ou l'autre catégorie (régime indéterminé). Cette décision détermine l'aiguillage du chiffre dans la suite du pipeline et met en œuvre directement l'hypothèse centrale du mémoire. Conformément au choix d'interprétabilité, la classification repose sur un faisceau de règles explicites plutôt que sur un classifieur opaque: chaque verdict de régime peut être justifié au lecteur par les marqueurs qui l'ont produit.

Cette section décrit d'abord les règles de classification et leurs résultats sur le corpus (2.4.1), puis le protocole de validation externe conçu pour en mesurer la fiabilité (2.4.2). Ce protocole n'a pas été mis en œuvre dans le cadre de ce mémoire ; sa description constitue le préalable méthodologique à toute publication consolidée des pourcentages avancés.

2.4.1 Règles de classification et résultats

La décision combine deux faisceaux d'indices. Les indices de régime 1 sont la présence d'un indicateur officiel identifié (taux de chômage, indice des prix, croissance du PIB, dette), l'attribution à une source officielle (INSEE, Eurostat, Banque de France) et l'emploi d'un verbe de constat (« s'établit à », « atteint », « ressort à »). Les indices de régime 2 sont les marqueurs de prévision ou d'intention (« objectif », « prévoit », « vise »), l'attribution à un acteur politique et l'emploi d'une grandeur budgétaire. Un système de scores arbitre entre les deux faisceaux, mais une règle de priorité s'impose: un chiffre prospectif, même portant sur un indicateur officiel, reste en régime 2, car une projection n'est pas un fait mesuré.

Une condition nécessaire structure l'ensemble: aucun claim ne peut être classé en régime 1 sans indicateur officiel explicitement identifié dans la phrase. Cette exigence corrige un biais majeur de la version initiale du classifieur, où la seule présence de l'unité « pourcentage » suffisait à faire basculer un chiffre en vérifiabilité forte ; ce critère trop lâche surévaluait massivement le régime 1 (plus de 3 700 claims). Trois exclusions explicites complètent le dispositif: les chiffres rattachés à un pays étranger sans source française (l'inflation espagnole n'est pas une observation INSEE), les références à une année future (objectifs et projections) et les ratios exprimés « en pourcentage du PIB » confondus avec le taux de croissance. Les affirmations qui

ne satisfont ni les indices de régime 1 ni ceux de régime 2, ou dont les faisceaux se contredisent, sont classées en régime indéterminé.

Appliqué aux 6 399 claims, le module classe 316 affirmations en régime 1 (5 %), 5 058 en régime 2 (79 %) et 1 025 en régime indéterminé (16 %). Au sein du régime 1, la répartition par indicateur est la suivante: inflation (167), chômage (82), PIB (28), déficit (24) et dette (15). Ce résultat confirme nettement l'hypothèse H1: la part des chiffres relevant de la vérifiabilité forte est minoritaire. Un vingtième du discours chiffré seulement renvoie à un indicateur officiel susceptible d'être confronté à une série de référence.

La portée de ce résultat doit toutefois être bornée par une limite assumée: la classification repose sur des règles dont le taux d'erreur n'a pas été mesuré par une procédure de validation externe. La section suivante décrit le protocole conçu à cette fin, dont la mise en œuvre reste à réaliser.

2.4.2 Protocole de validation du classifieur

La classification en régimes présentée dans la section précédente repose sur un faisceau de règles explicites. Cette transparence est une propriété méthodologique bienvenue, mais elle ne dispense pas d'une validation externe: un partage automatique entre régimes, si transparent soit-il, demeure une hypothèse sur le comportement des règles tant que sa concordance avec un jugement humain n'a pas été mesurée. Le protocole décrit ici précise la procédure retenue à cette fin ; sa mise en œuvre effective relève d'un travail d'annotation encore à réaliser, dont les résultats chiffrés sont laissés en attente.

Le protocole repose sur un échantillon d'environ cent affirmations chiffrées, tiré aléatoirement de l'ensemble des claims extraits du corpus, de manière à représenter la diversité des indicateurs et des formulations rencontrés. Cette taille d'échantillon correspond à l'ordre de grandeur usuel pour estimer un coefficient d'accord inter-codeurs avec une marge acceptable sur une classification à quelques modalités. Chaque affirmation de l'échantillon est soumise à une annotation manuelle indépendante, réalisée par au moins deux codeurs qui lui attribuent l'un des trois régimes (vérifiabilité forte, vérifiabilité faible, indéterminé), sur la base d'un guide de codage explicitant les critères de décision: présence d'un indicateur officiel identifié, caractère prospectif de l'énoncé, attribution à une source institutionnelle, ou absence de marqueurs discriminants pour le régime indéterminé. Le codage est effectué en aveugle par rapport à la

décision du classifieur automatique, afin de ne pas biaiser le jugement humain par la connaissance du verdict de la machine.

Deux mesures sont dérivées de cette annotation. La première est le pourcentage d'accord entre les codeurs et le classifieur, qui fournit une indication directe mais fruste de la fiabilité, puisqu'elle ne corrige pas l'accord dû au hasard. La seconde, plus robuste, est le coefficient kappa de Cohen (Cohen, 1960), qui mesure l'accord au-delà de ce que produirait une concordance aléatoire. Son interprétation s'appuie sur les seuils proposés par Landis et Koch (1977): un kappa inférieur à 0,40 traduit un accord faible, entre 0,41 et 0,60 un accord modéré, entre 0,61 et 0,80 un accord substantiel, et au-delà de 0,80 un accord quasi parfait. Ces seuils sont conventionnels et discutés dans la littérature (Artstein & Poesio, 2008), mais ils constituent le repère le plus couramment mobilisé en linguistique computationnelle. Le calcul de ce coefficient sur l'échantillon annoté fournira la marge d'erreur qui manque aujourd'hui aux pourcentages de la section 2.4.1 ; il constitue le prolongement méthodologique immédiat de ce travail. Tant que cette valeur n'est pas fixée, l'ordre de grandeur d'un régime 1 minoritaire doit être tenu pour robuste, mais le chiffre exact (5 %) pour provisoire.

Ce protocole ne vise pas à corriger le classifieur, mais à en quantifier la fiabilité et, le cas échéant, à identifier les catégories d'affirmations sur lesquelles les règles achoppent: chiffres ambigus, formulations elliptiques, ou indicateurs situés à la frontière des trois régimes. Il constitue le préalable méthodologique à toute publication des pourcentages comme résultats consolidés, et répond directement à la première des limites exposées en section 2.7.

2.5 Confrontation aux données officielles (INSEE)

Les affirmations de régime 1 sont dirigées vers la branche de fact-checking, qui confronte chaque chiffre à la valeur officielle correspondante. Cette confrontation suppose deux opérations distinctes: résoudre l'identifiant de la série statistique de référence (idBank) à partir de l'indicateur détecté, puis interroger la source officielle pour récupérer la valeur à la période visée. La source mobilisée est la Banque de données macroéconomiques (BDM) de l'INSEE, service web ouvert, sans authentification, conforme au standard SDMX et donnant accès à plus de 150 000 séries chronologiques (INSEE, 2024).

La correspondance entre indicateur et idBank constitue un choix méthodologique à part entière, car un même mot journalistique peut renvoyer à plusieurs séries. « Chômage » peut désigner le taux au sens du BIT ou les demandeurs d'emploi inscrits à France Travail, deux grandeurs distinctes qu'il serait erroné de comparer. Le module retient une série de référence par indicateur (taux de chômage BIT trimestriel, indice des prix mensuel, croissance trimestrielle du PIB, dette de Maastricht), en privilégiant le champ France entière, et écarte explicitement les sources hors périmètre INSEE. Le déficit public en pourcentage du PIB, qui ne fait pas l'objet d'une série servie par la BDM, est traité comme non vérifiable automatiquement.

Sur les 316 claims de régime 1, 292 idBank sont résolus, ce qui atteste la robustesse de la correspondance. Mais la récupération d'une valeur officielle exige une période précise: or seuls 42 claims citent un mois ou un trimestre identifiable permettant une comparaison directe à l'observation correspondante. Les autres ne mentionnent qu'une année, voire reçoivent leur période par défaut depuis la date de l'article (limite de résolution temporelle exposée en 2.3.2). Une exécution réelle contre l'API INSEE confirme ce diagnostic: la majorité des échecs d'appariement ne sont pas des erreurs techniques mais l'absence d'une période assez fine pour interroger une série mensuelle ou trimestrielle.

Ce résultat est le plus important de la branche de fact-checking, et il prolonge H1 au-delà de la simple classification: le chiffre réellement vérifiable est rare. Rapportés à l'univers de 6 399 affirmations, les quelque 42 claims directement confrontables représentent de l'ordre de 1 % du discours chiffré. L'absence de période précise n'est pas un défaut purement technique: elle est corrélée à la nature même des chiffres non vérifiables (objectifs, comparaisons, ratios, projections) qui ne sont par construction rattachés à aucune observation datée. La limite de la vérifiabilité se révèle ainsi plus étroite encore que ne le suggérait la seule classification en régimes.

Une réserve d'exécution doit être signalée. L'appariement réel suppose un accès en ligne à la BDM et la vérification préalable des identifiants de séries sur le portail de l'INSEE, les idBank pouvant évoluer. Le verdict de véracité proprement dit (module 4), qui mesure l'écart entre la valeur citée et la valeur officielle, ne produit de résultats publiables qu'une fois ces conditions réunies et la résolution temporelle fiabilisée. La contribution de cette section n'est donc pas un

taux de fausseté, mais la mesure de l'étroitesse du domaine sur lequel un tel taux pourrait être calculé.

2.6 Analyse de cadrage inter-médias

Les affirmations de régime 2, qui constituent l'écrasante majorité du corpus, ne peuvent être soumises à un verdict de véracité. Ce qui devient analysable est leur cadrage: la manière dont différents médias traitent le même événement chiffré. Le module 5 adopte une approche hybride, hiérarchisée. La mesure principale, dite de sélection, est inductive et non circulaire: sur l'ensemble des chiffres disponibles pour un événement, elle observe lesquels chaque média choisit de citer ou d'omettre. C'est une mesure objective (un chiffre est cité ou il ne l'est pas) qui ne suppose aucun cadre politique posé a priori et constitue la contribution propre du mémoire: le cadrage se révèle par la donnée elle-même.

Une mesure complémentaire, déductive, mobilise les quatre fonctions du cadrage d'Entman (1993): définition du problème, attribution causale, jugement moral, remède. Elles sont repérées par marqueurs lexicaux. Son statut est explicitement secondaire et interprétatif: le choix des marqueurs relève du codage de l'auteur, et un même mot peut servir des cadrages opposés. Elle n'est donc fournie qu'à titre d'éclairage, jamais comme preuve isolée, et le codebook correspondant figure en annexe pour validation ultérieure par double codage humain. Une mesure contextuelle neutre, celle des acteurs cités (gouvernement, opposition, experts, corps sociaux), situe enfin qui prend la parole.

L'unité d'analyse est l'événement: un même fait chiffré couvert par plusieurs médias. Les événements sont reconstruits en regroupant les articles par indicateur dominant et par semaine de publication, en ne retenant que les regroupements couverts par au moins trois médias distincts. Cette mise en œuvre, qui constitue un choix méthodologique discutable et à vérifier manuellement, produit 27 événements sur le corpus, portant majoritairement sur le chômage, l'inflation et la population.

Le résultat central confirme l'hypothèse H2. L'indice de divergence des sélections atteint 0,80 en moyenne (médiane 0,81), sur une échelle où 0 signifie que tous les médias citent les mêmes chiffres et 1 que leurs sélections sont disjointes. Autrement dit, face au même événement statistique, les rédactions citent massivement des chiffres différents ; les chiffres consensuels,

cités par tous les médias d'un événement, sont presque toujours absents. La sélection différenciée des données, mesurée sans recours à aucun profil éditorial posé a priori, révèle ainsi des cadrages distincts d'un même fait.

Ce résultat doit être lu avec ses limites. Les marqueurs Entman restent aveugles au sens et ne valent qu'à titre indicatif ; le découpage en événements dépend de paramètres (indicateur dominant, fenêtre hebdomadaire, seuil de trois médias) dont une variation modifierait les regroupements ; et certains événements, notamment ceux rattachés à la « population », reposent sur des mots-clés plus lâches qui appellent une vérification manuelle. Sous ces réserves, la divergence élevée et généralisée constitue le versant empirique du régime 2: là où la véracité est indécidable, le cadrage, lui, se mesure.

2.7 Synthèse des résultats et limites

Le pipeline, exécuté de bout en bout sur les 562 articles du corpus, produit un résultat d'ensemble cohérent qui valide les deux hypothèses de travail. Des 6 399 affirmations chiffrées extraites, 1 274 sont rattachées à un indicateur macroéconomique, 316 seulement (5 %) relèvent de la vérifiabilité forte, et de l'ordre de 42 (environ 1 % de l'univers chiffré) citent une période assez précise pour être directement confrontées à une série officielle. En parallèle, sur les chiffres de régime 2, l'analyse de cadrage révèle une divergence moyenne de 0,80 entre les sélections opérées par les médias pour un même événement.

Ces chiffres dessinent le résultat central du mémoire: la détectabilité de la désinformation par la donnée est structurellement asymétrique. Le fact-checking automatique, même techniquement abouti, ne s'applique qu'à une fraction marginale du discours chiffré, celle qui renvoie à une série officielle unique et datée. L'écrasante majorité des chiffres relève du cadrage: non pas faux, mais sélectionnés et contextualisés différemment selon les rédactions. La contribution propre de ce travail est de mesurer cette asymétrie empiriquement et de montrer que la non-vérifiabilité n'est pas l'exception mais la norme du chiffre journalistique. La frontière entre le vérifiable et le cadré devient elle-même un résultat, et non un simple préalable technique.

Cette conclusion s'accompagne de limites qui en bornent la portée et qu'il convient d'exposer sans détour. La première tient à la classification automatique: le partage entre régimes repose sur des règles dont le taux d'erreur n'a pas été mesuré ; une validation par double codage humain sur

un échantillon est nécessaire avant de fixer les pourcentages (protocole détaillé en 2.4.2). La deuxième concerne la résolution temporelle: en l'absence de mention explicite, la période d'un chiffre est héritée de la date de l'article, ce qui fragilise l'appariement aux séries infra-annuelles et explique l'étroitesse du sous-ensemble directement vérifiable.

La troisième limite porte sur l'analyse de cadrage: les marqueurs d'Entman sont interprétatifs et aveugles au sens, et le découpage en événements dépend de paramètres dont la variation modifierait les regroupements ; la validation par un coefficient d'accord inter-codeurs (kappa de Cohen) reste à conduire. La quatrième tient au périmètre du corpus: circonscrit à la presse écrite et au champ macroéconomique sur 2023-2024, il oriente les résultats vers un type de chiffre dont la vérifiabilité est a priori plus élevée que dans d'autres domaines ; la généralisation à l'audiovisuel, aux réseaux sociaux ou à d'autres thématiques demanderait une réplication. Enfin, le verdict de véracité proprement dit suppose une exécution en ligne contre l'API INSEE et la vérification préalable des identifiants de séries.

Loin d'invalider la démarche, ces limites en précisent la contribution. Ce travail ne prétend pas avoir construit un détecteur universel de désinformation chiffrée ; il démontre au contraire pourquoi un tel détecteur ne peut être qu'à portée restreinte, et il transforme cette restriction en mesure. En distinguant deux régimes de vérifiabilité et en quantifiant leurs poids respectifs, il fournit un cadre reproductible pour penser ce que la donnée permet et ne permet pas de vérifier dans le discours de presse. C'est dans cet écart, entre l'ambition du fact-checking automatique et son domaine réel d'application, que se situe l'apport de ce travail.

Partie III: Discussion et préconisations

La deuxième partie a mis à l'épreuve, sur un corpus de presse française, l'hypothèse des deux régimes de vérifiabilité. Les résultats convergent: la part des chiffres réellement confrontables à une série officielle est marginale, tandis que la sélection des chiffres non vérifiables diverge fortement d'un média à l'autre. Il reste à en tirer les conséquences: d'abord théoriques, ensuite opérationnelles. C'est l'objet de cette troisième partie.

La discussion (section 3.1) revient sur les deux hypothèses de travail au regard des chiffres obtenus, puis interprète le résultat central, celui de l'asymétrie de la vérifiabilité, en discussion avec la littérature mobilisée en partie 1. Les préconisations (section 3.2) en déduisent des recommandations concrètes, distinctes selon qu'elles s'adressent aux producteurs de l'information ou à ceux qui la vérifient. La section 3.3, enfin, expose les perspectives de recherche et les limites qui bornent la généralisation des conclusions. L'ensemble vise moins à clore le sujet qu'à préciser ce que la donnée permet, et ne permet pas, dans la lutte contre la désinformation chiffrée.

3.1 Discussion des résultats

3.1.1 Retour sur les hypothèses

Les résultats de la partie 2 permettent de statuer sur les deux hypothèses de travail. La première, selon laquelle la part des chiffres relevant de la vérifiabilité forte est minoritaire (H1), est nettement confirmée. Sur les 6 399 affirmations chiffrées extraites du corpus, 1 274 seulement (20 %) sont rattachées à un indicateur macroéconomique, et 316 (5 %) satisfont aux conditions du régime 1. Surtout, lorsqu'on exige une période d'observation assez précise pour interroger une série infra-annuelle, le sous-ensemble directement vérifiable se réduit à une quarantaine de claims, soit de l'ordre de 1 % du discours chiffré. La vérifiabilité forte n'est donc pas seulement minoritaire: elle est résiduelle.

La seconde hypothèse, selon laquelle la sélection des chiffres de régime 2 diverge fortement d'un média à l'autre pour un même événement (H2), est elle aussi confirmée. L'indice de divergence des sélections atteint 0,80 en moyenne sur les vingt-sept événements reconstruits, et les chiffres cités par l'ensemble des médias d'un même événement sont presque toujours absents. La

différence de traitement ne se loge pas d'abord dans le commentaire ou l'adjectif, mais en amont, dans le choix même des données portées à la connaissance du lecteur.

La conjonction de ces deux résultats dessine une conclusion qui dépasse la somme de ses parties. Là où le chiffre serait vérifiable, il est rare ; là où il est abondant, il n'est pas vérifiable mais sélectionné. Les deux régimes ne se contentent pas de coexister: ils se répartissent le discours chiffré de façon complémentaire et déséquilibrée, le second l'emportant massivement sur le premier. C'est cette asymétrie, et non l'existence isolée de chiffres faux, qui constitue l'élément central à interpréter.

Deux précautions doivent accompagner cette lecture. D'une part, les pourcentages reposent sur une classification automatique dont le taux d'erreur n'a pas été mesuré par double codage humain ; l'ordre de grandeur est robuste, mais le chiffre exact reste à consolider. D'autre part, le « 1 % » directement vérifiable est en partie un artefact de la résolution temporelle, qui n'identifie pas toujours une période pourtant présente dans le texte. La frontière réelle de la vérifiabilité se situe vraisemblablement un peu au-dessus de ce plancher, sans que cela modifie le constat d'ensemble d'un régime 1 très minoritaire.

3.1.2 L'asymétrie de la vérifiabilité: discussion théorique

L'asymétrie mise en évidence éclaire d'un jour nouveau les limites du fact-checking documentées en partie 1. La littérature a surtout analysé ces limites comme des obstacles techniques (couverture partielle, dépendance à des sources structurées, difficulté du raisonnement contextuel selon Graves, 2018). Les résultats invitent à les relire comme une propriété du matériau lui-même. Si le fact-checking automatique ne couvre qu'une fraction du discours, ce n'est pas seulement faute d'outils assez puissants, c'est parce que la majorité des chiffres ne possèdent pas de référent officiel unique auquel les confronter. La limite n'est pas seulement dans le détecteur ; elle est dans l'objet.

Ce déplacement rejoint la notion de malinformation (Wardle & Derakhshan, 2017): un chiffre exact mais sélectionné, décontextualisé ou cadré de manière orientée échappe par construction à une réfutation factuelle, puisque la donnée elle-même est correcte. Le régime 2 est précisément le domaine de cette malinformation chiffrée, où la question pertinente n'est plus « ce chiffre est-il vrai ? » mais « pourquoi ce chiffre-ci, et pas un autre ? ». La forte divergence des sélections

observée empiriquement donne une assise mesurable à l'intuition d'Entman (1993) selon laquelle cadrer, c'est d'abord sélectionner et rendre saillants certains aspects d'une réalité.

Un risque mérite d'être nommé: celui de l'illusion d'objectivité. Parce qu'il se présente sous une forme apparemment neutre et incontestable, le chiffre confère au discours qui le mobilise une autorité factuelle, alors même qu'il peut relever du régime 2 (objectif, projection ou estimation disputée). La présence d'une donnée numérique ne garantit donc pas la vérifiabilité ; elle peut au contraire la simuler. Ce constat a une portée critique directe: il invite à ne pas confondre la densité chiffrée d'un article avec sa rigueur factuelle, et à se méfier des dispositifs de vérification qui traiteraient tout nombre comme un fait à valider.

Sur le plan méthodologique, le travail illustre enfin l'intérêt d'une approche par règles interprétables plutôt que par apprentissage opaque. Chaque verdict de régime, chaque exclusion, chaque appariement peut être justifié et contesté, condition d'un usage défendable dans un contexte journalistique ou citoyen, où l'autorité d'un classement automatique ne peut reposer sur une boîte noire. Cette transparence a un coût en couverture et en finesse, assumé au profit de la traçabilité: un système de vérification de l'information doit lui-même être vérifiable.

Reste une question ouverte que les résultats posent sans la trancher: l'asymétrie observée est-elle propre au champ macroéconomique et à la presse écrite, ou constitue-t-elle une régularité plus générale du discours chiffré ? Les indicateurs conjoncturels, adossés à des séries officielles bien établies, représentent sans doute le cas le plus favorable à la vérification. Dans des domaines aux référents plus fragmentés, comme la santé, la sécurité ou l'environnement, la part du régime 1 pourrait être plus faible encore, renforçant la thèse de l'asymétrie. Cette généralisation, qui excède le corpus mobilisé, est discutée parmi les perspectives de recherche (section 3.3).

3.2 Préconisations

3.2.1 Préconisations pour les rédactions

Le premier enseignement opérationnel s'adresse aux producteurs de l'information. Si une part aussi faible des chiffres de presse est directement vérifiable, c'est en partie parce que les conditions de leur vérifiabilité ne sont pas réunies à la source. L'analyse a montré que le verrou principal n'est pas l'exactitude des chiffres mais leur ancrage: un nombre devient vérifiable

lorsqu'il est accompagné de sa période d'observation précise et de la source officielle dont il est issu. Or ces deux éléments manquent dans la majorité des affirmations du corpus, ce qui les fait basculer, indépendamment de leur véracité, hors du champ du contrôle factuel.

La première préconisation est donc d'ordre rédactionnel: dater et sourcer systématiquement les chiffres conjoncturels. Écrire « le chômage s'établit à 7,5 % au quatrième trimestre 2023 selon l'INSEE » plutôt que « le chômage est autour de 7,5 % » ne relève pas du détail typographique. C'est la différence entre un chiffre vérifiable et un chiffre qui ne l'est pas. Cette discipline, déjà inscrite dans les chartes des rédactions de référence, gagnerait à être systématisée et outillée, par exemple par des gabarits de relecture signalant les chiffres dépourvus de période ou de source.

La deuxième préconisation concerne la distinction des statuts. Le travail a montré qu'un même habillage numérique recouvre des réalités hétérogènes: une mesure officielle, une prévision, un objectif politique, un ratio construit. Confondre ces statuts entretient l'illusion d'objectivité décrite en 3.1.2. Il serait utile que les rédactions explicitent, dans la formulation même, le statut du chiffre cité (mesure constatée, projection, estimation), afin que le lecteur ne prête pas à une intention la force d'un fait. Cette explicitation est d'autant plus nécessaire que les chiffres prospectifs, par nature non vérifiables, sont fréquemment mobilisés dans le débat public avec l'autorité des chiffres mesurés.

La troisième préconisation porte sur le cadrage. Puisque la divergence inter-médias se loge d'abord dans la sélection des chiffres, une rédaction soucieuse de pluralisme gagnerait à interroger ses propres omissions: quels chiffres disponibles sur un événement n'ont pas été cités, et pourquoi ? Sans postuler qu'il existe une sélection neutre, car toute mise en récit sélectionne, la conscience explicite de cette sélection constitue un garde-fou contre le cadrage involontaire. Les outils d'analyse développés dans ce mémoire, qui rendent visible l'univers des chiffres d'un événement et la part qu'en retient chaque média, pourraient y contribuer comme instruments de réflexivité éditoriale.

3.2.2 Préconisations pour les fact-checkers et les plateformes

Le second ensemble de préconisations s'adresse à ceux qui vérifient l'information: rédactions spécialisées, fact-checkers et plateformes. Le résultat central impose un changement de perspective. Un système de vérification automatique ne doit pas viser l'ensemble du discours

chiffré, mais reconnaître d'abord à quel régime appartient chaque affirmation, puis lui appliquer le traitement adéquat. Tenter de « fact-checker » un objectif politique ou une prévision revient à poser une question mal formée ; à l'inverse, traiter un taux officiel daté comme une simple opinion néglige une vérification pourtant possible.

Pour le régime 1, la préconisation est d'automatiser la vérification là où elle est fiable, c'est-à-dire sur le noyau de chiffres rattachables à une série officielle et datés. Sur ce périmètre restreint mais bien défini, l'appariement à une source comme la Banque de données macroéconomiques de l'INSEE permet un verdict reproductible. Les systèmes de priorisation des affirmations dignes de vérification, dont la littérature a montré l'efficacité (Hassan et al., 2017), trouvent ici leur emploi le plus pertinent: non pour trancher la véracité de tout chiffre, mais pour identifier rapidement le petit ensemble sur lequel un verdict automatique est défendable, et concentrer l'effort humain sur le reste.

Pour le régime 2, qui concentre l'essentiel du discours, la préconisation est de déplacer l'effort de la vérification vers la contextualisation. Puisque la question de la véracité y est mal posée, l'apport d'un outil n'est pas de produire un verdict vrai/faux, mais de restituer le contexte: rappeler l'univers des chiffres disponibles sur un événement, signaler ceux que le média a omis, expliciter le statut du chiffre cité (objectif, prévision, ratio). Cette assistance au cadrage, plutôt qu'au fact-checking, répond plus justement à la nature des chiffres concernés et évite l'écueil du faux verdict, qui décrédibilise les dispositifs de vérification lorsqu'ils tranchent l'indécidable.

Une mise en garde s'impose enfin à l'égard des plateformes et des systèmes d'étiquetage automatique. La tentation de comparer mécaniquement tout chiffre à une base de référence produirait, comme l'a illustré la partie 2, de faux écarts: confronter une inflation étrangère, un objectif daté ou un ratio à une série française génère des verdicts erronés à grande échelle. Un dispositif d'étiquetage doit donc intégrer en amont la classification des régimes, sous peine de transformer un outil de vérification en source de désinformation. La prudence commande de réserver le verdict automatique au seul régime 1 vérifiable, et de traiter le régime 2 par la mise en contexte plutôt que par le jugement.

3.3 Perspectives et limites de la recherche

Les conclusions de ce travail doivent être lues à l'aune de leurs limites, qui dessinent en creux un programme de recherche.

La première limite tient à la validation de la classification. Le partage entre régimes, comme la détection des fonctions de cadrage, repose sur des règles dont la fiabilité n'a pas été quantifiée par une procédure externe. Aucun échantillon de claims n'a été soumis à un double codage humain dans le cadre de ce mémoire, et aucun coefficient d'accord inter-codeurs (kappa de Cohen) n'a été calculé. Cette validation constitue la première priorité méthodologique pour les travaux futurs: elle permettrait d'assortir les pourcentages avancés d'une marge d'erreur et de consolider, voire de corriger, l'ordre de grandeur observé. En l'état, la robustesse du résultat repose sur la clarté des règles et la cohérence interne du classement, non sur une mesure externe de leur fiabilité.

La deuxième limite concerne la résolution temporelle, identifiée comme le principal verrou de la branche de vérification. Le repli systématique sur la date de l'article, en l'absence de période explicite, sous-estime le nombre de chiffres réellement datables. Une extraction temporelle plus fine, capable de capter les références trimestrielles ou mensuelles présentes dans la phrase mais non adjacentes à une année, et de distinguer la période extraite de la période héritée par défaut, élargirait le noyau vérifiable et fiabiliserait le verdict. Cette amélioration, circonscrite et réaliste, constitue le prolongement technique le plus immédiat.

La troisième limite porte sur le périmètre du corpus. Restreint à la presse écrite, au champ macroéconomique et à la période 2023-2024, il représente le cas le plus favorable à la vérification, les indicateurs conjoncturels étant adossés à des séries officielles bien établies. Trois axes de réplication s'en déduisent. Le premier est l'extension à d'autres domaines aux référents plus fragmentés (santé, sécurité, environnement), où l'asymétrie pourrait être plus marquée encore. Le deuxième est l'ouverture à d'autres supports, notamment l'audiovisuel et les réseaux sociaux, qui constituent des vecteurs majeurs de circulation de la désinformation contemporaine (Vosoughi, Roy & Aral, 2018 ; Bronner, 2022). Le troisième est l'élargissement temporel, pour tester la stabilité des résultats hors d'une conjoncture particulière.

Un quatrième axe relève de la consolidation du dispositif de vérification lui-même. Le verdict de véracité suppose une exécution en ligne contre l'API de l'INSEE et la vérification préalable des

identifiants de séries, qui peuvent évoluer. Son industrialisation demanderait un suivi de la correspondance entre indicateurs et séries, ainsi qu'une gestion des révisions statistiques. Au-delà, l'enrichissement de l'analyse de cadrage, par l'intégration d'autres dimensions que la seule sélection des chiffres, ou par une validation qualitative des regroupements d'événements, affinerait la mesure de la divergence inter-médias.

Ces limites, loin d'affaiblir la portée du travail, en circonscrivent la contribution avec précision. Le mémoire n'a pas construit un détecteur universel de désinformation chiffrée ; il a montré, en le mesurant, pourquoi un tel détecteur ne peut être qu'à portée restreinte, et il a proposé un cadre reproductible pour penser ce que la donnée permet de vérifier dans le discours de presse: la distinction des deux régimes de vérifiabilité. C'est dans cet écart entre l'ambition affichée du fact-checking automatique et son domaine réel d'application que réside l'apport de cette recherche, et c'est cet écart que les travaux futurs auront à explorer.

Conclusion générale

Ce mémoire est parti d'une question simple en apparence: dans quelle mesure peut-on détecter de la désinformation médiatique par la donnée ? Reformulée en termes opérationnels, elle interrogeait la possibilité d'automatiser la vérification des chiffres de la presse française par recoupement avec les sources officielles. Pour y répondre, un pipeline modulaire et interprétable a été appliqué à un corpus de 562 articles de la presse économique et généraliste, sur la période 2023-2024, autour d'un cadre analytique central: l'hypothèse des deux régimes de vérifiabilité, qui distingue les chiffres rattachables à une série officielle unique (régime 1) de ceux qui, dépourvus de référent, ne relèvent que du cadrage (régime 2).

Les résultats confirment les deux hypothèses de travail. Sur les 6 399 affirmations chiffrées extraites du corpus, 316 seulement (soit 5 %) satisfont aux conditions de la vérifiabilité forte, et le sous-ensemble réellement confrontable à une série officielle datée se réduit à une quarantaine de claims, de l'ordre de 1 % du discours chiffré. L'hypothèse d'un régime 1 minoritaire se trouve non seulement confirmée mais radicalisée, le vérifiable se révélant résiduel plutôt que simplement rare. La seconde hypothèse est elle aussi vérifiée: sur les vingt-sept événements reconstruits, l'indice de divergence des sélections atteint 0,80 en moyenne, signe que les rédactions citent massivement des chiffres différents pour rendre compte d'un même fait. De la conjonction de ces deux résultats se dégage la thèse centrale du travail: la détectabilité de la désinformation par la donnée est structurellement asymétrique. Là où le chiffre serait vérifiable, il est rare ; là où il abonde, il n'est pas faux mais sélectionné. La non-vérifiabilité n'est pas l'exception du discours chiffré, elle en est la norme.

Ce résultat éclaire d'un jour nouveau les limites du fact-checking documentées dans la littérature. Là où celle-ci les analysait surtout comme des obstacles techniques (couverture partielle, dépendance à des sources structurées, difficulté du raisonnement contextuel selon Graves, 2018), le mémoire invite à les relire comme une propriété du matériau lui-même. Si l'automatisation ne couvre qu'une fraction du discours, ce n'est pas seulement faute d'outils assez puissants, mais parce que la majorité des chiffres ne possèdent aucun référent officiel unique auquel les confronter. Le régime 2 constitue ainsi le domaine propre de la malinformation chiffrée (Wardle & Derakhshan, 2017), où la question pertinente n'est plus « ce chiffre est-il vrai ? » mais « pourquoi ce chiffre-ci, et pas un autre ? ». La densité numérique d'un article ne garantit donc nullement sa rigueur factuelle: le nombre peut simuler la vérifiabilité autant qu'il l'atteste.

Ce constat emporte des conséquences opérationnelles, développées dans les préconisations de la troisième partie. Il invite d'abord les rédactions à dater et à sourcer systématiquement leurs chiffres conjoncturels, condition première de leur vérifiabilité, et à expliciter le statut de chaque donnée citée (mesure constatée, prévision ou objectif), afin de dissiper l'illusion d'objectivité que le nombre entretient. Il conduit ensuite à préconiser, pour les fact-checkers et les plateformes, un traitement différencié selon le régime: réserver le verdict automatique au seul régime 1, où l'appariement à une source comme l'INSEE autorise une vérification reproductible, et traiter le régime 2 par la contextualisation plutôt que par le jugement. Un dispositif d'étiquetage qui confronterait mécaniquement tout chiffre à une base de référence produirait, faute de cette distinction, de faux verdicts à grande échelle, transformant l'outil de vérification en source de désinformation.

Ces conclusions doivent être lues à l'aune de leurs limites. La classification en régimes repose sur des règles dont le taux d'erreur n'a pas été mesuré par une validation externe: aucun échantillon de claims n'a été soumis à un double codage humain dans le cadre de ce travail, et aucun coefficient d'accord inter-codeurs n'a été calculé. L'ordre de grandeur est robuste, mais le chiffre exact reste à consolider. La résolution temporelle, qui fait retomber par défaut un chiffre sur la date de son article, sous-estime probablement le noyau réellement vérifiable. Enfin, le périmètre du corpus (presse écrite, champ macroéconomique, années 2023-2024) représente le cas le plus favorable à la vérification, ce qui borne la portée des résultats sans en renverser le sens.

Ces limites dessinent en creux un programme de recherche. La priorité méthodologique consiste à mener la validation par double codage humain sur un échantillon représentatif, assortie d'un coefficient d'accord inter-codeurs, qui permettrait d'assortir les pourcentages d'une marge d'erreur. Trois axes de réplication s'en déduisent ensuite. Le premier est l'extension à d'autres domaines aux référents plus fragmentés, tels que la santé ou la sécurité, où l'asymétrie pourrait être plus marquée encore. Le deuxième est l'ouverture à l'audiovisuel et aux réseaux sociaux. Le troisième est l'industrialisation du verdict INSEE, qui suppose un suivi des identifiants de séries et une gestion des révisions statistiques. Au terme de ce parcours, la contribution du mémoire tient moins à un taux de désinformation qu'il aurait mesuré qu'à la mise au jour d'un écart: celui qui sépare l'ambition affichée du fact-checking automatique de son domaine réel d'application.

Reconnaître cet écart, et en faire un objet de mesure plutôt qu'un angle mort, c'est déjà rendre au chiffre journalistique la part d'incertitude que son apparente objectivité dissimule.

Bibliographie

Les références sont présentées par ordre alphabétique du nom du premier auteur, selon les normes APA (7e édition). Les titres d'ouvrages et de revues figurent en italique.

A

Allcott, H., & Gentzkow, M. (2017). Social media and fake news in the 2016 election. *Journal of Economic Perspectives, 31*(2), 211-236. https://doi.org/10.1257/jep.31.2.211

Amazeen, M. A. (2020). Journalistic interventions: The structural factors affecting the global emergence of fact-checking. *Journalism, 21*(1), 95-111. https://doi.org/10.1177/1464884917730217

Angeli, G., Manning, C. D., & Jurafsky, D. (2012). Parsing time: Learning to interpret time expressions. In *Proceedings of the 2012 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT 2012)* (pp. 446-455). Association for Computational Linguistics.

Arslan, F., Hassan, N., Li, C., & Tremayne, M. (2020). A benchmark dataset of check-worthy factual claims. In *Proceedings of the International AAAI Conference on Web and Social Media, 14*(1), 821-829. https://doi.org/10.1609/icwsm.v14i1.7346

Artstein, R., & Poesio, M. (2008). Survey article: Inter-coder agreement for computational linguistics. *Computational Linguistics, 34*(4), 555-596. https://doi.org/10.1162/coli.07-034-R2

Auer, S., Bizer, C., Kobilarov, G., Lehmann, J., Cyganiak, R., & Ives, Z. (2007). DBpedia: A nucleus for a web of open data. In *The Semantic Web (ISWC 2007)* (pp. 722-735). Springer. https://doi.org/10.1007/978-3-540-76298-0_52

B

Badouard, R., Mabi, C., & Sire, G. (2016). Beyond "points of control": Logics of digital governmentality. *Internet Policy Review, 5*(3). https://doi.org/10.14763/2016.3.433

Batini, C., & Scannapieco, M. (2016). *Data and information quality: Dimensions, principles and techniques*. Springer. https://doi.org/10.1007/978-3-319-24106-7

Best, J. (2001). *Damned lies and statistics: Untangling numbers from the media, politicians, and activists*. University of California Press.

Blastland, M., & Dilnot, A. (2007). *The tiger that isn't: Seeing through a world of numbers*. Profile Books.

Brandtzaeg, P. B., Følstad, A., & Chaparro Domínguez, M. Á. (2018). How journalists and social media users perceive online fact-checking and verification services. *Journalism Practice, 12*(9), 1109-1129. https://doi.org/10.1080/17512786.2017.1363657

Bronner, G. (2013). *La démocratie des crédules*. Presses Universitaires de France.

Bronner, G. (dir.). (2022). *Les Lumières à l'ère numérique*. Rapport de la commission remis au Président de la République, 11 janvier 2022. Présidence de la République.

C

Cardon, D., Cointet, J.-P., & Mazières, A. (2018). La revanche des neurones. L'invention des machines inductives et la controverse de l'intelligence artificielle. *Réseaux, 211*(5), 173-220. https://doi.org/10.3917/res.211.0173

Chang, A. X., & Manning, C. D. (2012). SUTime: A library for recognizing and normalizing time expressions. In *Proceedings of the Eighth International Conference on Language Resources and Evaluation (LREC 2012)* (pp. 3735-3740). European Language Resources Association.

Chen, C.-C., Huang, H.-H., & Chen, H.-H. (2020). NumClaim: Investor's fine-grained claim detection. In *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM '20)* (pp. 1973-1976). https://doi.org/10.1145/3340531.3412100

Chen, W., Wang, H., Chen, J., Zhang, Y., Wang, H., Li, S., Zhou, X., & Wang, W. Y. (2020). TabFact: A large-scale dataset for table-based fact verification. In *Proceedings of the International Conference on Learning Representations (ICLR 2020)*. https://arxiv.org/abs/1909.02164

Chiticariu, L., Li, Y., & Reiss, F. R. (2013). Rule-based information extraction is dead ! Long live rule-based information extraction systems ! In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing (EMNLP 2013)* (pp. 827-832). Association for Computational Linguistics.

Coddington, M. (2015). Clarifying journalism's quantitative turn: A typology for evaluating data journalism, computational journalism, and computer-assisted reporting. *Digital Journalism, 3*(3), 331-348. https://doi.org/10.1080/21670811.2014.976400

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37-46. https://doi.org/10.1177/001316446002000104

Cohen, S., Hamilton, J. T., & Turner, F. (2011). Computational journalism: A call to arms to database researchers. In *Proceedings of the 5th Biennial Conference on Innovative Data Systems Research (CIDR 2011)* (pp. 148-151).

Cucerzan, S. (2007). Large-scale named entity disambiguation based on Wikipedia data. In *Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL 2007)* (pp. 708-716). Association for Computational Linguistics.

D

Diakopoulos, N. (2019). *Automating the news: How algorithms are rewriting the media*. Harvard University Press.

E

Entman, R. M. (1993). Framing: Toward clarification of a fractured paradigm. *Journal of Communication, 43*(4), 51-58. https://doi.org/10.1111/j.1460-2466.1993.tb01304.x

F

Flew, T., Spurgeon, C., Daniel, A., & Swift, A. (2012). The promise of computational journalism. *Journalism Practice, 6*(2), 157-171. https://doi.org/10.1080/17512786.2011.616655

Friedl, J. E. F. (2006). *Mastering regular expressions* (3rd ed.). O'Reilly Media.

Fu, Y., Guo, S., Hoffswell, J., Bursztyn, V. S., Rossi, R., & Stasko, J. (2024). "The data says otherwise" — Towards automated fact-checking and communication of data claims. In *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology (UIST '24)*. ACM. https://doi.org/10.1145/3654777.3676359

G

Graves, L. (2016). *Deciding what's true: The rise of political fact-checking in American journalism*. Columbia University Press.

Graves, L. (2018). Understanding the promise and limits of automated fact-checking. *Reuters Institute for the Study of Journalism, Factsheet*. University of Oxford.

Graves, L., & Cherubini, F. (2016). *The rise of fact-checking sites in Europe*. Reuters Institute for the Study of Journalism, University of Oxford.

Grishman, R., & Sundheim, B. (1996). Message Understanding Conference-6: A brief history. In *Proceedings of the 16th Conference on Computational Linguistics*

(COLING 1996) (Vol. 1, pp. 466-471). Association for Computational Linguistics. https://doi.org/10.3115/992628.992709

Grover, C., Matheson, C., Mikheev, A., & Moens, M. (2000). LT TTT — A flexible tokenisation tool. In *Proceedings of the Second International Conference on Language Resources and Evaluation (LREC 2000)*. European Language Resources Association.

Guo, Z., Schlichtkrull, M., & Vlachos, A. (2022). A survey on automated fact-checking. *Transactions of the Association for Computational Linguistics, 10*, 178-206. https://doi.org/10.1162/tacl_a_00454

H

Hassan, N., Adair, B., Hamilton, J. T., Li, C., Tremayne, M., Yang, J., & Yu, C. (2015). The quest to automate fact-checking. In *Proceedings of the 2015 Computation + Journalism Symposium*. Columbia University.

Hassan, N., Li, C., & Tremayne, M. (2015). Detecting check-worthy factual claims in presidential debates. In *Proceedings of the 24th ACM International Conference on Information and Knowledge Management (CIKM '15)* (pp. 1835-1838). https://doi.org/10.1145/2806416.2806652

Hassan, N., Zhang, G., Arslan, F., Caraballo, J., Jimenez, D., Gawsane, S., Hasan, S., Joseph, M., Kulkarni, A., Nayak, A. K., Sable, V., Li, C., & Tremayne, M. (2017). ClaimBuster: The first-ever end-to-end fact-checking system. *Proceedings of the VLDB Endowment, 10*(12), 1945-1948. https://doi.org/10.14778/3137765.3137815

Honnibal, M., & Montani, I. (2017). *spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing* [Software]. Explosion AI.

Huff, D. (1954). *How to lie with statistics*. W. W. Norton & Company.

I

INSEE. (2024). *Banque de données macroéconomiques (BDM)* [Base de données]. Institut national de la statistique et des études économiques. https://www.insee.fr/fr/statistiques

J

Janssen, M., Charalabidis, Y., & Zuiderwijk, A. (2012). Benefits, adoption barriers and myths of open data and open government. *Information Systems Management, 29*(4), 258-268. https://doi.org/10.1080/10580530.2012.716740

K

Kantar Public, & La Croix. (2019). *Baromètre de la confiance des Français dans les médias — 32e édition*. La Croix. https://www.la-croix.com

Kotonya, N., & Toni, F. (2020). Explainable automated fact-checking: A survey. In *Proceedings of the 28th International Conference on Computational Linguistics (COLING 2020)* (pp. 5430-5443). https://doi.org/10.18653/v1/2020.coling-main.474

L

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics, 33*(1), 159-174. https://doi.org/10.2307/2529310

M

Martin, L., Muller, B., Ortiz Suárez, P. J., Dupont, Y., Romary, L., de la Clergerie, É. V., Seddah, D., & Sagot, B. (2020). CamemBERT: A tasty French language model. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020)* (pp. 7203-7219). https://doi.org/10.18653/v1/2020.acl-main.645

N

Naumann, F. (2002). *Quality-driven query answering for integrated information systems* (LNCS Vol. 2261). Springer. https://doi.org/10.1007/3-540-45921-9

P

Pariser, E. (2011). *The filter bubble: What the internet is hiding from you*. Penguin Press.

Pennycook, G., & Rand, D. G. (2021). The psychology of fake news. *Trends in Cognitive Sciences, 25*(5), 388-402. https://doi.org/10.1016/j.tics.2021.02.007

Porter, T. M. (1995). *Trust in numbers: The pursuit of objectivity in science and public life*. Princeton University Press.

R

Rao, D., McNamee, P., & Dredze, M. (2013). Entity linking: Finding extracted entities in a knowledge base. In T. Poibeau, H. Saggion, J. Piskorski, & R. Yangarber (Eds.), *Multi-source, multilingual information extraction and summarization* (pp. 93-115). Springer. https://doi.org/10.1007/978-3-642-28569-1_5

S

Sagot, B., & Boullier, P. (2008). SxPipe 2: Architecture pour le traitement présyntaxique de corpus bruts. *Traitement Automatique des Langues, 49*(2), 155-188.

Shen, W., Wang, J., & Han, J. (2015). Entity linking with a knowledge base: Issues, techniques, and solutions. *IEEE Transactions on Knowledge and Data Engineering, 27*(2), 443-460. https://doi.org/10.1109/TKDE.2014.2327028

Silverman, C. (Ed.). (2016). *Verification handbook: A definitive guide to verifying digital content for emergency coverage*. European Journalism Centre.

Stencel, M., & Griffin, R. (2020). *Fact-checkers extend their global reach with 290 outlets, but growth has slowed*. Duke Reporters' Lab. https://reporterslab.org

Strötgen, J., & Gertz, M. (2013). Multilingual and cross-domain temporal tagging. *Language Resources and Evaluation, 47*(2), 269-298. https://doi.org/10.1007/s10579-012-9179-y

Sunstein, C. R. (2001). *Republic.com*. Princeton University Press.

T

Tandoc, E. C., Lim, Z. W., & Ling, R. (2018). Defining "fake news": A typology of scholarly definitions. *Digital Journalism, 6*(2), 137-153. https://doi.org/10.1080/21670811.2017.1360143

Thorne, J., Vlachos, A., Christodoulopoulos, C., & Mittal, A. (2018). FEVER: A large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT 2018)* (pp. 809-819). https://doi.org/10.18653/v1/N18-1074

V

Vlachos, A., & Riedel, S. (2014). Fact checking: Task definition and dataset construction. In *Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science* (pp. 18-22). Association for Computational Linguistics. https://doi.org/10.3115/v1/W14-2508

Vlachos, A., & Riedel, S. (2015). Identification and verification of simple claims about statistical properties. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP 2015)* (pp. 2596-2601). https://doi.org/10.18653/v1/D15-1312

Vosoughi, S., Roy, D., & Aral, S. (2018). The spread of true and false news online. *Science, 359*(6380), 1146-1151. https://doi.org/10.1126/science.aap9559

W

Wardle, C., & Derakhshan, H. (2017). *Information disorder: Toward an interdisciplinary framework for research and policymaking* (Report DGI(2017)09). Council of Europe.

Z

Zuiderwijk, A., & Janssen, M. (2014). Open data policies, their implementation and impact: A framework for comparison. *Government Information Quarterly, 31*(1), 17-29. https://doi.org/10.1016/j.giq.2013.04.003

Glossaire

Le glossaire ci-dessous recense les acronymes, termes techniques et expressions en langue étrangère mobilisés dans le mémoire. Les entrées sont classées par ordre alphabétique.

A

API (Application Programming Interface). Interface de programmation d'application. Ensemble de protocoles et de fonctions permettant à deux logiciels de communiquer, ici entre le pipeline et les bases de données de l'INSEE.

Attachement de numéral (numeral attachment). Opération consistant à relier un nombre extrait d'un texte à l'entité qu'il qualifie (par exemple rattacher « 7,3 % » à « inflation »). Notion introduite dans le champ du traitement de textes financiers.

B

BDM (Banque de données macroéconomiques). Service web de l'INSEE exposant depuis 2015 plus de 150 000 séries chronologiques macroéconomiques françaises, accessibles gratuitement via une API conforme au standard SDMX.

BIT (Bureau international du travail). Organe permanent de l'Organisation internationale du travail. Le chômage « au sens du BIT » désigne une définition internationale harmonisée, distincte de l'inscription administrative auprès de France Travail.

C

Cadrage (framing). Concept issu des sciences de la communication (Entman, 1993) désignant la manière dont un discours sélectionne et met en saillance certains aspects d'une réalité au détriment d'autres. Objet central de l'analyse du régime 2.

CamemBERT. Modèle de langue français pré-entraîné (Martin et al., 2020), état de l'art pour plusieurs tâches de traitement automatique du français, dont la reconnaissance d'entités nommées.

Check-worthy (affirmation digne de vérification). Qualifie une affirmation factuelle jugée suffisamment saillante ou consequente pour mériter une vérification, par opposition à un énoncé subjectif ou à un fait mineur.

Cherry-picking statistique. Sélection orientée de faits ou de chiffres exacts pour appuyer une thèse, en occultant les données qui la contrediraient. Forme typique de malinformation chiffrée.

Claim. Affirmation factuelle vérifiable extraite d'un texte. Dans ce mémoire, désigne spécifiquement les phrases contenant une donnée chiffrée susceptible de faire l'objet d'un traitement automatisé.

ClaimBuster. Système de fact-checking automatisé développé par l'Université du Texas (Hassan et al., 2017), premier dispositif de bout en bout combinant détection, priorisation et vérification d'affirmations.

CLEF (Conference and Labs of the Evaluation Forum). Conférence internationale annuelle consacrée à l'évaluation des systèmes de recherche d'information et de traitement automatique des langues. Organise notamment le CheckThat ! Lab sur la vérification factuelle.

D

DBpedia. Base de connaissances extraite automatiquement de Wikipédia (Auer et al., 2007), fournissant des faits structurés interrogeables par machine.

Désinformation. Diffusion délibérée d'informations fausses dans le but de tromper. Se distingue de la mésinformation par l'intention de nuire (Wardle & Derakhshan, 2017).

Désordre informatif (information disorder). Cadre théorique proposé par Wardle et Derakhshan (2017) regroupant sous un même terme la mésinformation, la désinformation et la malinformation. Vise à dépasser le vocabulaire imprécis des « fake news ».

E

Entity linking (appariement d'entités). Opération consistant à relier une mention textuelle (par exemple « le chômage des jeunes ») à son référent dans une base de connaissances (par exemple une série statistique de l'INSEE identifiée par un idBank).

Eurostat. Office statistique de l'Union européenne. Publie des données harmonisées entre pays membres, conformes au standard SDMX, qui permettent des recoupements avec les statistiques nationales telles que celles de l'INSEE.

F

Fact-checking (vérification factuelle). Activité, d'origine journalistique, consistant à confronter une affirmation à des sources faisant autorité pour en établir la véracité. Peut être manuelle ou automatisée.

FEVER (Fact Extraction and VERification). Jeu de données de référence (Thorne et al., 2018) rassemblant 185 445 affirmations dérivées de Wikipédia, servant de banc d'essai à la vérification factuelle contre du texte non structuré.

H

HeidelTime. Étiqueteur temporel multilingue et interdomaine (Strötgen & Gertz, 2013), reposant sur un ensemble de règles pour reconnaître et normaliser les expressions temporelles.

I

idBank. Identifiant unique attribué par l'INSEE à chaque série chronologique de la Banque de données macroéconomiques. Permet d'interroger une valeur pour une période donnée par appel à l'API.

INSEE (Institut national de la statistique et des études économiques). Institut national français chargé de la production, de l'analyse et de la diffusion de la statistique publique. Source de référence pour les indicateurs macroéconomiques du corpus.

K

Kappa de Cohen (κ). Coefficient statistique (Cohen, 1960) mesurant l'accord entre deux évaluateurs qui classent des items dans des catégories, en corrigeant l'accord attendu par hasard. Utilisé pour la validation externe de la classification en régimes.

M

Malinformation. Diffusion d'éléments exacts mais mobilisés pour porter préjudice, par exemple par décontextualisation ou sélection orientée. Troisième forme de désordre informatif chez Wardle et Derakhshan (2017).

Mésinformation. Diffusion d'une information fausse sans intention de nuire, par exemple une erreur ou une approximation. Se distingue de la désinformation par l'absence d'intention (Wardle & Derakhshan, 2017).

N

NER (Named Entity Recognition). Reconnaissance d'entités nommées. Tâche de traitement automatique des langues consistant à repérer dans un texte les mentions d'entités telles que personnes, lieux, dates, quantités ou pourcentages.

NumClaim. Tâche de détection fine d'affirmations chiffrées en domaine financier (Chen, Huang & Chen, 2020), centrée sur les données numériques des textes d'investisseurs.

O

Open data (données ouvertes). Politique et pratique de mise à disposition libre et réutilisable de jeux de données publics. En France, portée notamment par la plateforme data.gouv.fr opérée par Etalab.

P

PIB (Produit intérieur brut). Indicateur macroéconomique mesurant la valeur totale des biens et services produits sur un territoire pendant une période donnée. Publié en France par l'INSEE selon un calendrier trimestriel.

Pipeline. Chaîne de traitement modulaire dans laquelle chaque étape produit une sortie exploitable par l'étape suivante. Choix méthodologique central du dispositif empirique, visant l'interprétabilité et la reproductibilité.

Q

QuanTemp. Jeu de données spécifiquement construit pour la vérification d'affirmations numériques et temporelles, mobilisé dans la tâche 3 du CheckThat ! Lab de CLEF 2025.

R

Régime de vérifiabilité. Notion centrale du mémoire distinguant deux catégories d'affirmations chiffrées. Le régime 1 rassemble les chiffres rattachables à une série officielle unique, justiciables d'un verdict de véracité. Le régime 2 rassemble les chiffres sans référent officiel, qui ne peuvent être analysés que sous l'angle du cadrage.

REST (REpresentational State Transfer). Style d'architecture logicielle utilisé pour les services web, notamment celui de l'INSEE, qui repose sur des requêtes HTTP standard permettant l'interrogation programmatique de ressources distantes.

S

SDMX (Statistical Data and Metadata eXchange). Standard international pour l'échange de données statistiques et de leurs métadonnées. Adopté par l'INSEE et Eurostat, il garantit l'interopérabilité entre sources statistiques nationales et européennes.

spaCy. Bibliothèque Python de traitement automatique du langage (Honnibal & Montani, 2017), qui propose des composants de mise en correspondance de motifs et des modèles pré-entraînés pour de nombreuses langues dont le français.

SUTime. Étiqueteur temporel développé à Stanford (Chang & Manning, 2012), reposant sur des règles pour reconnaître et normaliser les expressions temporelles.

T

TabFact. Jeu de données conçu pour la vérification d'affirmations face à une preuve structurée sous forme de tables (Chen et al., 2020). Comprend 117 854 énoncés annotés portant sur 16 573 tables issues de Wikipédia.

Note relative à l'usage de l'intelligence artificielle

Conformément aux exigences de l'INSEEC en matière d'intégrité académique, la présente note précise le recours à des outils d'intelligence artificielle dans la réalisation de ce mémoire.

Des assistants d'intelligence artificielle ont été mobilisés à deux fins précises. La première est l'aide à la génération et au débogage du code du pipeline de traitement. La seconde est l'assistance à la reformulation et à la relecture rédactionnelle de certains passages, afin d'en améliorer la clarté et la correction linguistique.

En revanche, les décisions de fond relèvent entièrement de l'auteur. La collecte du corpus sur Europresse a été conduite manuellement. Les choix méthodologiques ont été arrêtés par l'auteur, qu'il s'agisse de la définition du cadre des deux régimes de vérifiabilité, de la fixation des seuils de tolérance, de la sélection des identifiants de séries de l'INSEE ou de la construction des règles de classification. L'interprétation des résultats et la construction de l'argumentation lui reviennent également.

Aucune donnée, aucun résultat chiffré et aucune référence bibliographique n'ont été produits ou complétés par un outil d'intelligence artificielle. Les données proviennent de l'exécution effective du pipeline, et les sources citées ont été vérifiées individuellement. Cet usage est conforme aux recommandations du guide méthodologique de l'INSEEC, qui admet l'assistance par l'intelligence artificielle sous réserve de sa mention explicite et du maintien de la responsabilité intellectuelle de l'auteur.

Résumé

Ce mémoire interroge la possibilité de détecter la désinformation médiatique par la donnée, en se demandant dans quelle mesure la vérification des chiffres de la presse française peut être automatisée par recoupement avec les sources officielles. À partir d'un corpus de 562 articles de la presse économique et généraliste (2023-2024), un pipeline modulaire et interprétable extrait les affirmations chiffrées, les classe selon deux régimes de vérifiabilité et confronte les chiffres vérifiables aux séries de l'INSEE. Les résultats mettent en évidence une asymétrie structurelle: seuls 5 % des chiffres relèvent d'une vérifiabilité forte, et environ 1 % sont directement confrontables à une série officielle datée, tandis que la sélection des chiffres non vérifiables diverge fortement d'un média à l'autre (indice de divergence moyen de 0,80). Le fact-checking automatique ne s'applique donc qu'à une fraction marginale du discours chiffré ; l'essentiel relève du cadrage. Le mémoire en tire des préconisations pour les rédactions et les vérificateurs, et propose un cadre reproductible pour distinguer ce que la donnée permet, et ne permet pas, de vérifier.

Mots-clés: désinformation, fact-checking automatisé, données chiffrées, cadrage, presse française, INSEE, journalisme computationnel.

Abstract

This dissertation examines whether media disinformation can be detected through data, asking to what extent the verification of numerical claims in the French press can be automated by cross-checking against official sources. Drawing on a corpus of 562 articles from the economic and general press (2023-2024), a modular and interpretable pipeline extracts numerical claims, classifies them according to two regimes of verifiability, and confronts the verifiable figures with INSEE time series. The findings reveal a structural asymmetry: only 5% of the figures fall under strong verifiability, and about 1% can be directly matched to a dated official series, whereas the selection of non-verifiable figures diverges sharply across outlets (average divergence index of 0.80). Automated fact-checking therefore applies only to a marginal fraction of numerical discourse ; the bulk pertains to framing. The dissertation derives recommendations for newsrooms and fact-checkers, and offers a reproducible framework for distinguishing what data can, and cannot, verify.

Keywords: disinformation, automated fact-checking, numerical data, framing, French press, INSEE, computational journalism.